



华南理工大学
South China University of Technology

本科毕业设计（论文）

基于深度学习的仪表示数识别系统

学 院 未来技术学院

专 业 人工智能

学生姓名 俞铭一

学生学号 202130192499

指导教师 吴瀚聪

提交日期 2025 年 5 月 1 日

华南理工大学

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：  日期： 2025 年 5 月 31 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

作者签名：  日期： 2025 年 5 月 31 日
指导教师签名：  日期： 2025 年 6 月 4 日
作者联系电话： 18260083796 电子邮箱： yumingyi2003@gmail.com

摘要

本文提出了一种基于 YOLOv8 模型的自动化仪表读数系统，专门针对数显式与指针式仪表在图像处理与读数识别中的关键问题，设计了优化的算法流程。系统以高精度为基础，同时兼顾性能和资源使用效率，采用轻量化的 YOLOv8n 模型，在充分考虑本地硬件资源约束的前提下，有效提升了运行效率与调试便捷性。

针对数显式仪表，系统构建了包含数显区域检测、图像增强与数字识别等模块的处理链路，并通过自主设计的数字排列识别算法，实现了高准确度的读数解析；而在指针式仪表部分，则结合表盘区域检测、图像增强与畸变校正等关键技术，配合自主开发的指针角度计算算法，成功实现了指针读数的精确获取。

根据实验结果的分析，各模块在准确率方面均表现优异：指针式仪表表盘检测模型的识别准确率达到 97%，数显式仪表区域检测准确率为 92.68%，其数字识别模块准确率为 88%，指针式仪表特征识别准确率为 93.8%。最终的整体读数效果方面，数显仪表的读数准确率为 96.4%，指针式仪表的读数成功率达 100%，其读数结果与人工标注值的平均相对误差控制在 0.8% 以内。

因此，本系统在准确性、运行效率及硬件适应性等方面表现突出，具有良好的实用价值与工程推广前景。

关键词：自动仪表读数；YOLOv8；图像处理；数显式仪表；指针式仪表

Abstract

This paper presents an automated instrument reading system based on the YOLOv8 architecture, specifically tailored for both digital and analog (pointer-type) gauges. Addressing the challenges of image processing and recognition for these two types of meters, the system introduces optimized algorithms and a streamlined processing workflow. Emphasizing a balance between accuracy and computational efficiency, a lightweight YOLOv8n model is employed, selected to align with local hardware constraints while ensuring smooth system operation and ease of debugging.

For digital meters, the system integrates modules for display region detection, image enhancement, and digit recognition. A custom-developed digit arrangement parsing algorithm enables precise numerical readings. For pointer-type gauges, the approach combines dial region detection, image enhancement, and distortion correction techniques with a self-designed angle-based pointer reading algorithm, ensuring accurate interpretation of pointer positions.

Experimental evaluations demonstrate strong performance across all components: the pointer gauge dial detection model achieved a 97% accuracy rate; the digital display region detection model reached 92.68%; the digit recognition module for digital meters achieved 88% accuracy; and the pointer feature recognition model achieved 93.8%. Overall, the system yielded a 96.4% reading accuracy for digital meters and a 100% reading success rate for pointer meters, with an average relative error of less than 0.8% when compared to manually annotated values.

In conclusion, the proposed system demonstrates high practical value and strong potential for real-world deployment. Its robust performance and adaptability to hardware constraints make it a promising solution for automated inspection and remote monitoring in sectors such as power, chemical processing, and water utilities.

Keywords: Automatic meter reading; YOLOv8; Image processing; Digital meters; Analog meters

目 录

摘要	I
Abstract	II
目录	I
第一章 绪论	1
1.1 引言	1
1.2 研究背景	1
1.3 国内外研究现状	2
1.4 论文结构	3
第二章 YOLOv8 模型的基础知识	4
2.1 YOLOv8 模型结构	4
2.1.1 Backbone (主干网络)	4
2.1.2 Neck (特征融合)	5
2.1.3 Head (预测头)	5
2.2 YOLOv8 推理过程	5
2.2.1 图像预处理	6
2.2.2 特征提取与融合	6
2.2.3 多尺度预测张量输出	6
2.2.4 边界框解码	6
2.2.5 非极大值抑制	7
2.3 YOLOv8 训练策略	7
2.3.1 动态标签分配	7
2.3.2 多样化数据增强	8
2.3.3 联合损失函数设计	8
2.4 本章小结	9
第三章 实验数据集解释	10
3.1 数显仪表数显区域检测模型训练数据集解释	10

3.2	数显式仪表示数识别模型训练数据集解释.....	11
3.3	指针式仪表表盘检测模型训练数据集解释.....	12
3.4	指针式仪表特征识别模型训练数据集解释.....	14
3.5	本章小结.....	15
第四章	基于深度学习的仪表示数识别系统设计.....	16
4.1	YOLOv8 模型尺寸选择	16
4.2	数显式仪表读数系统设计.....	16
4.2.1	数显仪表读数区域识别.....	18
4.2.2	数显仪表读数区域处理.....	18
4.2.3	数显仪表示数识别.....	19
4.2.4	数显仪表示数读数.....	19
4.3	指针式仪表读数系统设计.....	20
4.3.1	指针式仪表表盘检测.....	20
4.3.2	指针式仪表表盘区域处理.....	21
4.3.3	指针式仪表特征识别.....	22
4.3.4	指针式仪表示数读数.....	22
4.4	本章小结.....	23
第五章	数显仪表示数识别系统实验结果与分析.....	25
5.1	数显式仪表数显区域检测模型.....	25
5.1.1	模型训练过程.....	25
5.2	数显式仪表示数识别模型.....	28
5.2.1	模型训练过程.....	28
5.3	数显式仪表读数.....	30
5.3.1	数显式仪表表盘检测结果.....	30
5.3.2	数显仪表读数区域处理结果.....	31
5.3.3	数显仪表示数识别结果.....	32
5.3.4	数显仪表示数读数结果.....	33
5.3.5	数显仪表读数小结.....	34

5.4	本章小结.....	34
第六章	指针仪表示数识别系统实验结果与分析.....	35
6.1	指针式仪表表盘检测模型.....	35
6.1.1	模型训练过程.....	35
6.2	指针式仪表特征识别（指针与刻度始末区域）模型.....	38
6.2.1	模型训练过程.....	39
6.3	指针式仪表读数.....	41
6.3.1	指针式仪表表盘检测结果.....	41
6.3.2	指针式仪表表盘区域处理结果.....	42
6.3.3	指针式仪表特征识别结果.....	43
6.3.4	指针式仪表示数读数结果.....	43
6.3.5	指针式仪表读数小结.....	45
6.4	本章小结.....	45
结论	46
1.	论文工作总结	46
2.	工作展望	46
参考文献	48
致谢	50

第一章 绪论

1.1 引言

作为最基本和基础的监测设备，指针和数字仪表多年来一直普遍用于工业、能源和环境监测系统的数据收集和状态反馈。在监测生产环境中工业设备的运行状态时，各类仪表的读数是否准确性并及时都会直接影响系统的安全性及其管理效率。然而，当前绝大多数场景仍采用人工方式进行仪表读数，不仅费时费力，还存在误读、漏读等人为风险，难以满足现代工业对智能化、自动化的高要求。

近年来，随着人工智能和计算机视觉技术的发展，国内外的工业 4.0 逐渐步入正轨，各行各业的智能化自动化成为热门的研究方向。在各种深度学习方法的推动下，目标检测与图像识别技术取得了显著进展，为本文仪表读数的自动化提供了技术基础。虽然传统图像处理方法在特定条件下可实现部分自动识别功能，但对光照变化、拍摄角度、仪表类型等敏感性较高，适应性与鲁棒性不足。所以开发出一种基于深度学习的、稳定高效的仪表读数识别方法具有重要的研究价值和广泛的应用前景。

而本论文就旨在研究并实现一套基于深度学习的仪表示数自动识别系统，将采用 YOLOv8 作为主要的目标检测模型，融合图像处理与字符识别技术，实现对指针式和数显式仪表的自动检测、定位与读数提取，从而提升工业界仪表数据收集的智能化水平，为工业界监测系统的升级提供技术升级的思路。

1.2 研究背景

指针式和数显式仪表的自动读数，本质上是一种目标检测和图像理解的任务。指针式仪表要读取数据，需要准确识别表盘上的刻度并计算指针所指的角度；对于数显式仪表，则需要先定位数字显示区域，然后再识别其中的字符。传统的仪表识别方法一般采用边缘检测、霍夫变换、轮廓分析等图像处理技术来提取仪表的结构和特征，但这些方法往往依赖于手工设定的规则，在多变复杂的环境中鲁棒性较差，难以有效应对各种仪表的变化。随着深度学习的快速发展，仪表识别也出现了新的技术路线。卷积神经网络（CNN）在图像分类和目标检测方面的广泛应用，使得基于数据驱动的模型能够在复杂背景中保持较高的识别精度。目前，像 Faster R-CNN、YOLO 系列、SSD 等经典目

标检测算法都已被应用到工业视觉系统中。其中，YOLO 系列采用了端到端的结构，具有良好的实时性和较高的检测准确率，因此受到广泛关注。YOLOv8 是该系列中较新的版本，在网络结构、检测精度和推理速度等方面做了全面优化。新版本引入了无锚框（Anchor-Free）机制，并进行了模型轻量化设计，这不仅提升了检测性能，还降低了对计算资源的需求，使其更容易在实际部署时快速响应。由于 YOLOv8 对多种类型、特别是小目标具有很强的检测能力，因此它能够更好地适应现实场景中指针式和数显式仪表的复杂多样性。在指针式仪表的识别过程中，基于 YOLOv8 的检测框架可以首先准确定位出仪表的整体区域和指针的位置。随后，结合图像校正和指针角度计算等技术，就能自动计算并提取指针所指示的读数。对于数显式仪表，识别过程也相对简洁：可以先通过检测算法找到数字显示区域，然后配合训练好的字符识别模型，高效提取显示出的数字和关键信息，从而实现对表盘数据的精准读取。

1.3 国内外研究现状

目前，国内外在仪表的自动识别领域已取得了大量研究成果。随着深度学习技术的快速发展，图像检测与分割方法，如 Faster R-CNN、Mask R-CNN 等，被广泛应用于指针式和数显式仪表的自动读取任务中。这些方法有效提升了识别的准确率和鲁棒性，但在复杂背景、仪表倾斜、光照不均或指针重叠等实际应用场景下仍面临一定挑战。因此，研究更为精准、高效、适应性更强的仪表识别方法仍具有重要的学术研究意义与实际应用价值。以下为对国内外一些研究成果的归纳与概括：

近年来，基于深度学习与计算机视觉的自动表计读取技术取得了显著进展。Laroca 等人提出了一种两阶段方法，利用 Fast-YOLO 精确定位电表区域，并结合卷积神经网络（CNN）实现字符识别，该方法还发布了 UFPR-AMR 数据集，为后续研究提供了标准基准^[1]。Salomon 等人进一步拓展了对指针式电表的研究，构建了 UFPR-ADMR 数据集，并通过 Faster R-CNN 与 YOLO 实现了高效的表盘检测与指针角度回归^[2]。Imran 等人则针对数字电能表，设计了一种基于图像分割与 OCR 技术的自动抄表系统，兼具鲁棒性与可扩展性^[3]。Liu 等人面向工业环境中的模拟指针仪表，提出了结合 YOLOX-DC 与 Transformer 分割网络的端到端识别框架，有效应对了复杂背景与光照变化带来的挑战^[4]。此外，还有研究采用 OCR 与深度学习结合的方法，全面提升了图

像中表计数字识别的精度与效率，进一步推动了抄表系统的智能化与自动化发展^[5]。周登科等人针对指针式仪表拍摄角度倾斜的问题，提出了一种基于深度学习的图像校正方法，显著提高了读数的准确性^[6]。

在指针分割精度方面，Fang 基于 Mask R-CNN 提出了一种自动读取方法，不仅能精确认识到指针位置，还能分割出完整指针区域，从而更准确地提取读数，尤其适用于背景复杂、指针重叠的场景^[7]。此外，Kanagarathinam 等人研究了在七段数字能量表图像中进行文本检测与识别的方法，通过图像预处理与深度模型识别，有效提高了数字读取的鲁棒性和准确度^[8]。

可以得知，当前仪表识别研究主要聚焦于：（1）结合目标检测与 OCR 技术提升数显仪表识别精度；（2）结合深度学习与图像处理方法优化指针识别与角度计算；（3）利用分割网络提升复杂背景下指针提取能力；（4）通过图像校正增强系统对拍摄倾斜与畸变的适应性。这些研究为本课题的开展提供了良好的理论基础与技术参考，但仍需进一步提升系统的通用性、实时性和对复杂场景的鲁棒性。

1.4 论文结构

本文一共分为四个大章。其中第一章简述了仪表示数识别的实际意义和研究背景以及对现有的一些相关研究成果的分析与总结等。第二章节从 YOLOv8 的模型结构，模型推理过程，训练策略三方面详细的讲述了本论文在研究过程中运用的 YOLOv8 模型的基础知识。第三章针对仪表示数识别系统各模块模型训练以及后续的处理过程。第四章节是关于仪表示数识别系统实验各模块的结果与相关数据分析。

第二章 YOLOv8 模型的基础知识

2.1 YOLOv8 模型结构

不同于 YOLOv5/YOLOv7, YOLOv8 的结构有了比较明显的改进, 其中最大的三个特点就是各模块相对前版本模型进行了简化、模型支持了 Anchor-Free 结构, 以及多种多样的模型尺寸设计 (可分为 n/s/m/l/x)。虽然结构发生了不小的变化, 但是其整体的网络结构仍然保持着 Backbone–Neck–Head 的经典三段式整体架构。

YOLOv8 模型的整体神经网络架构可以分为 Backbone 模块, Neck 模块, Head 模块共三大模块。

其中 Backbone 模块主要用于从输入的图像中提取多层次的特征; Neck 模块主要用于融合 Backbone 模块提取的多尺度的图像特征, 从而增强上下文信息; 而 Head 模块就用来实现图像检测目标框的回归与类别预测。在 YOLOv8 模型中, 这三个模块通过 Tensor 传递实现了无缝的对接, 这就使得 YOLOv8 特别适合端到端的训练与本地部署。

2.1.1 Backbone (主干网络)

此模块是模型整个目标检测神经网络中最重要的组件, 正如上文所说, 主要被用于从原始的输入图像中提取纹理, 语义等等的多尺度特征。而 YOLOv8c 此模块就是基于 CSPDarknet (Cross Stage Partial Darknet) 架构进行优化, 因此具有轻量化、高性能的特点。它的核心模块为 C2f (Cross Stage Partial with Focus), 既可以高效地提取多尺度特征又能同时保持梯度流通以减少信息损失^[9]。

C2f 的整体流程基本为先输入特征图, 待其被分割后分别将其送入多个 Bottleneck 层, 并最终在输出端进行融合 (如公式 (1) 所示):

$$Y = \text{Concat}(X_1, \text{Bottleneck}_1(X_2), \dots, \text{Bottleneck}_n(X_n)) \quad (1)$$

其中的 Concat 表示通道维度的拼接, Bottleneck 则使用残差结构促进深层信息学习。

此外, YOLOv8 还使用了 SiLU (Sigmoid-Weighted Linear Unit) 作为激活函数, 经研究证明, 这种非线性激活函数在性能的提升与训练的稳定性都是高于传统的 ReLU

激活函数的^[10]。

2.1.2 Neck (特征融合)

为了增强上下文信息，YOLOv8 使用了 Neck 模块用于融合 Backbone 模块提取的多尺度的图像特征。这个特征融合网络同时采用了 FPN (Feature Pyramid Network) 与 PAN (Path Aggregation Network) 两种架构进行组合，以此在多个不同层级的特征图信息之间建立高性能的信息流通路径^{[11][12]}。

特征融合可以拆分为两个部分，分别自上向下的特征增强（FPN 架构）与自上向下的路径聚合（PAN）：

$$F_i^{FPN} = \text{Conv}(F_i) + \text{Upsample}(F_{i+1}) \quad (2)$$

$$F_i^{PAN} = \text{Conv}(\text{Concat}(F_i, \text{Downsample}(F_{i-1}))) \quad (3)$$

如公式 (2) 公式 (3) 所示，其中 F_i 表示来自第 i 层的特征，Conv 表示 1×1 或 3×3 的卷积，而 Upsample 和 Downsample 分别是上采样和下采样。

经研究证明，这种上下双向的信息流通架构机制可以有效提升模型检测对于多尺度目标的感知能力，并在处理小目标时更加优秀。

2.1.3 Head (预测头)

为了实现图像检测目标框的回归与类别预测，YOLOv8 的预测头采用了解耦头 (Decoupled Head)，将分类和回归两个任务分别进行处理，大幅提升了模型的精度和鲁棒性。最后模型的各个 Head 将分别输出：边界框回归(x, y, w, h)，置信度 p_{obj} ，类别概率 p_c 。

最终的预测结果将呈现为：

$$\hat{y} = [x, y, w, h, p_{obj}, p_1, \dots, p_c] \quad (4)$$

2.2 YOLOv8 推理过程

YOLOv8 的推理流程实现了端到端的单阶段目标检测，保持了 YOLO 系列一贯的高效风格。整体流程包括图像预处理、特征提取与融合、多尺度预测、边界框解码与非

极大值抑制。不同于前代模型，YOLOv8 在推理结构中引入 anchor-free 架构，极大简化了边界框生成流程，并减少了后处理的计算复杂度。

2.2.1 图像预处理

YOLOv8 会首先将输入图像进行缩放至固定尺寸（正如本文中模型训练均将其缩放至 640×640 ），并同时进行归一化操作（如公式（5）所示）：

$$I' = \frac{I}{255.0}, \quad I' \in [0,1] \quad (5)$$

除此以外，为了尽量减少目标因长宽比变化而变形提高检测的准确率下，YOLOv8 还会采用 letterbox 填充将输入图像自动适配网络输入尺寸。

2.2.2 特征提取与融合

输入图像进行预处理后，将正式进入推理阶段，上一节介绍的 Backbone 和 Neck 模块将分别提取语义与空间信息，而 Head 模块将在不同的尺度上输出对应的预测张量。

每个预测层将检测不同大小的目标，通过 FPN 和 PAN 混合架构，充分整合多尺度上下文信息，提升检测目标的定位准确率^[13]。

2.2.3 多尺度预测张量输出

YOLOv8 的预测头输出为一个三维张量：三位分别为当前特征图的空间分辨率；每个位置预测的边界框参数（通常为四个：x, y, w, h）；类别数量。

不同于 YOLOv5/YOLOv4 中的 anchor-based 框，YOLOv8 采用 anchor-free 的中心点框架，仅基于单一预测点产生边界框。

2.2.4 边界框解码

在 anchor-free 架构中，预测框的中心点(x, y)是在当前格点坐标基础上进行偏移计算的（如公式（6），公式（7）所示）：

$$x = \frac{i + \sigma(\Delta x)}{S}, \quad y = \frac{j + \sigma(\Delta y)}{S} \quad (6)$$

$$w = e^{\Delta w}, \quad h = e^{\Delta h} \quad (7)$$

其中(i, j)为当前特征图上的网格位置, σ 表示 sigmoid 函数用于归一化偏移。最终边界框坐标为:

$$B = [x - \frac{w}{2}, y - \frac{h}{2}, x + \frac{w}{2}, y + h/2] \quad (8)$$

2.2.5 非极大值抑制

在所有候选框解码完成之后, YOLOv8 将会使用 NMS 进行冗余检测框的抑制。标准 NMS 算法如下:

设有预测框集合 $\{B_k\}$, 每个框附有置信度 s_k 。NMS 迭代选择最大置信度框 B_m , 并抑制与其 IoU 超过阈值 τ (默认值 ≈ 0.6) 的框:

$$IoU(B_m, B_k) > \tau \rightarrow \text{discard } B_k \quad (9)$$

2.3 YOLOv8 训练策略

YOLOv8 的训练策略可以说融合运用了多项先进的深度学习训练技术。这些技术进一步提升了模型在执行目标检测任务中的准确率与收敛效率。它的核心策略包括动态标签分配、多样化数据增强, 以及结构化的联合损失函数设计。在训练的过程中, 这些策略相辅相成, 使 YOLOv8 在保持较低计算复杂度的同时获得了更高的检测精度。

2.3.1 动态标签分配

标签分配策略是目标检测模型中正负样本划分的核心。在传统的 YOLO 模型中, 通常使用固定阈值或 anchor-based 分配方式。但 YOLOv8 继承了 YOLOX 的思想^[14], 采用 Dynamic K Matching 策略实现 anchor-free 的目标对齐机制。

在每次迭代中, 对于每一个 Ground Truth 边界框 g_j , 模型会计算其与预测框集合 $\{p_i\}$ 的匹配代价 $Cost_{i,j}$, 定义如下:

$$Cost_{i,j} = \lambda_{cls} \cdot L_{cls}(p_i, g_j) + \lambda_{iou} \cdot L_{iou}(p_i, g_j) \quad (10)$$

其中： L_{cls} 表示分类损失，通常使用 Binary Cross Entropy； L_{IoU} 表示预测框与 GT 框的 IoU 损失，常采用 G_{IoU} 、 D_{IoU} 或 C_{IoU} ； $\lambda_{cls}, \lambda_{iou}$ 为加权因子。

随后，根据代价最小的前 K 个预测框与该 GT 框建立匹配关系，其中 K 是动态计算的，通常基于预测框与 GT 框的 IoU 排名决定。这种机制相比固定匹配策略更具弹性，能够提升小目标与重叠目标的匹配质量。

2.3.2 多样化数据增强

为了增强模型的泛化能力与鲁棒性，YOLOv8 在训练中广泛使用了数据增强技术（图像级与实例级都有）。这些技术有效扩大了训练样本的分布范围，并最终有效提升了模型对不同场景下目标的检测能力。

而其中，最引人注目的数据增强技术就是 Mosaic 增强。该增强方式将四张图像拼接为一张图像，如图 2-1 所示，通过随机缩放、裁剪和拼接操作提升小目标检测能力。该技术在 YOLOv4 中被第一次提出，并且已被证实对 mAP 有显著提升。

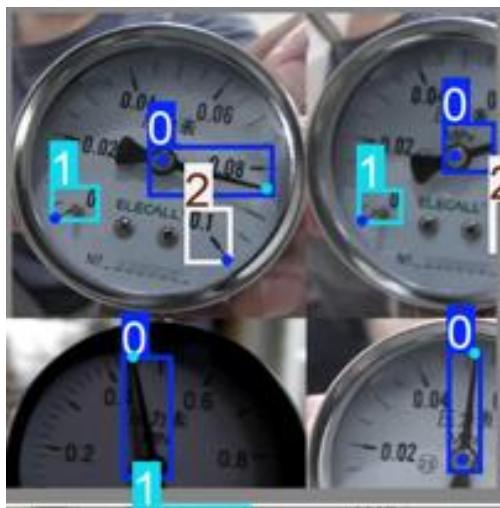


图 2-1 Mosaic 增强实例

2.3.3 联合损失函数设计

YOLOv8 的损失函数沿用了 YOLO 系列多任务损失结构，整合了边界框回归、目标置信度与分类预测三个子任务。这种结构化损失组合使 YOLOv8 能同时优化位置、置信度与类别的预测能力，在各类目标检测任务中表现出较强的通用性与鲁棒性。

$$L_{total} = \lambda_{box} \cdot L_{box} + \lambda_{obj} \cdot L_{obj} + \lambda_{cls} \cdot L_{cls} \quad (11)$$

其中： L_{box} ：使用 CIoU 损失衡量预测框与真实框之间的匹配质量； L_{obj} ：采用 Binary Cross Entropy (BCE) 衡量目标存在概率； L_{cls} ：采用 BCE with Logits (或 Focal Loss) 衡量多类别分类误差。

2.4 本章小结

本章从模型结构，模型推理过程，训练策略三个大方面对本论文主要使用的 YOLOv8 模型进行了较为深度的剖析。

YOLOv8 的核心架构包括主干网络、特征融合结构和预测头。YOLOv8 作为 YOLO 系列的最新版本，在模型设计上进行了显著优化。主干网络引入 C2f 模块，提升特征提取能力与模型计算效率；Neck 采用 PAN 与 FPN 相结合的路径增强结构，有效融合不同尺度的语义信息；而预测头则摒弃了传统 Anchor-Based 架构，采用 Anchor-Free 设计，进一步简化检测框架并提升了小目标检测性能。

YOLOv8 的训练策略结合了 CIoU 损失函数、动态标签分配算法、数据增强手段以及 EMA 模型参数更新机制，从多个维度提升模型的收敛速度、泛化能力与检测准确率。

在模型的推理过程中，YOLOv8 首先对输入图像进行归一化与缩放，然后通过主干与 Neck 提取多尺度特征，预测张量经解码得到边界框信息。推理阶段使用 NMS 去除冗余框，最终输出高置信度的目标检测结果。

YOLOv8 在保持 YOLO 系列一贯的高效性基础上，显著提升了检测精度与适应性，是当前目标检测任务中的优秀代表。

第三章 实验数据集解释

3.1 数显仪表数显区域检测模型训练数据集解释

(数据集来源: <https://wenku.csdn.net/doc/7jggfn3cwa>)

数显式仪表数显区域训练数据集提供了一个包含 2680 张标注完整的.jpg 图像及其对应的标注文件集合, 且为了提高模型的泛化能力和鲁棒性, 数据集通过图像旋转、缩放和平移等操作进行了数据增强。经过预处理, 将整个数据集按照常规比例 train:val:test =8:1:1 进行了划分。将需要检测得到的读数区域标记为“reading-region”, 观察下方数显式仪表数显区域检测训练数据集标签统计与可视化的图像(图 3-1)后发现, 此类别实例有超过 2000+ 的数量, 证明数据量较为充分。且观察所有标注框的形状与位置重叠图发现其密集成同心矩形分布, 说明标注框的形状高度一致。

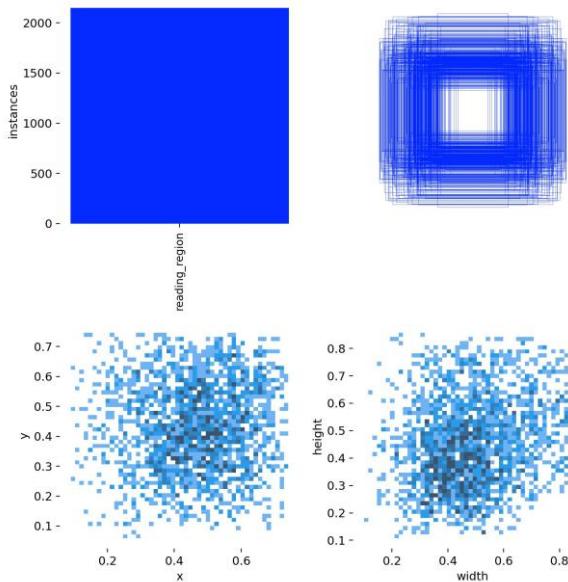


图 3-1 数显式仪表表盘检测训练数据集标签统计与可视化

如图 3-2, 图 3-3 所示, 每个对应的.txt 标注文件都记录了每张图像的标注信息, 格式遵循 YOLO 标注标准。前 5 个参数是 YOLO 的原生格式, 包括类别、中心坐标 (x, y)、宽 (w) 和高 (h)。后 8 个参数是读数区域四个角点的归一化坐标, 分别表示左上、右上、右下和左下的坐标 ($x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4$)。



图 3-2 数显式仪表表盘检测训练数据集图像

0 0.47048826420467593 0.4252813375591383 0.42173533599742785 0.2562123926324009 0.25962059620596206 0.43089430894308944
0.6378531073446327 0.29717514124293787 0.6813559322033899 0.42033898305084744 0.29268292682926833 0.5533875338753388

|图 3-3 数显式仪表表盘检测训练数据集图像对应标注信息

3.2 数显式仪表示数识别模型训练数据集解释

(数据来源：https://download.csdn.net/download/weixin_43387635/88464215?spm=1001.2014.3001.5503)

本模型训练使用的数据集包含共计 1156 张图像，主要用于训练和评估数字识别模型在模拟万用表读数任务中的性能。为提升模型的泛化能力并确保评估的客观性，数据集被划分为训练集、验证集和测试集三部分。其中，训练集包含 702 张图像，占总数据量的约 60%，用于模型参数的学习；验证集包含 228 张图像，占比约 20%，用于在训练过程中评估模型性能并指导超参数调整，以防止过拟合现象；测试集则由 226 张图像组成，约占 20%，用于在模型训练完成后对其泛化能力进行独立评估。

该数据集涵盖了 12 个类别（如图 3-4 所示），包括数字 0 至 9、负号 “-” 以及小数点 “.”，以模拟万用表读数的多样性和复杂性。这要求模型不仅能识别单个数字，还需理解符号组合所代表的具体数值，如 “-3.14” 与 “3.14” 的差异，或小数点在读数中所处的位置。

在模型训练前，所有图像均需经过预处理操作，包括尺寸缩放、像素归一化以及边界框（bounding box）标注。每张图像中所有目标字符（数字或符号）均配有相应的边

界框及类别标签，用于指导 YOLO 模型在检测过程中同时完成目标定位与分类任务。

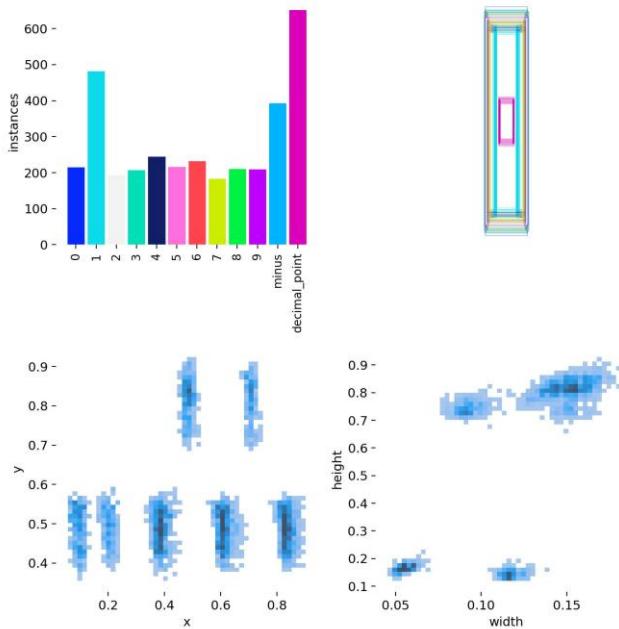


图 3-4 数显式仪表示数识别训练数据集标签统计与可视化

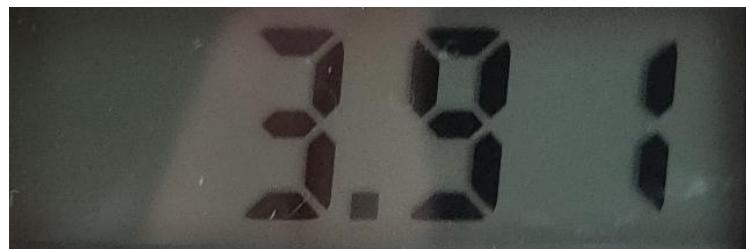


图 3-5 数显式仪表示数识别训练数据集图像

```
3 0.382812 0.478571 0.146875 0.814286
11 0.478125 0.814286 0.056250 0.171429
9 0.604688 0.485714 0.146875 0.819048
1 0.871875 0.485714 0.087500 0.742857
```

图 3-6 数显式仪表示数识别训练数据集图像对应标注信息

如图 3-5, 图 3-6 所示, 每个对应的.txt 标注文件都记录了每张图像的标注信息, 格式遵循 YOLO 标注标准。参数是 YOLO 的原生格式, 包括类别、中心坐标 (x, y)、宽 (w) 和高 (h)。

3.3 指针式仪表表盘检测模型训练数据集解释

(数据来源: <https://aistudio.baidu.com/datasetdetail/124339>)

指针式仪表表盘检测训练数据集分为两个部分, 分别是训练集 725 例, 验证集 58

例。将检测得到的指针表盘区域标记为“pointmeter”，观察下方指针式仪表表盘检测训练数据集标签统计与可视化的图像（图 3-7）后发现，此类别实例有超过 900+ 的数量，证明数据量较为充分。且观察所有标注框的形状与位置重叠图发现其密集成同心矩形分布，说明标注框的形状高度一致，下图右侧的 width-height 分布图数据成单一窄带分布，进一步证明了此结论。

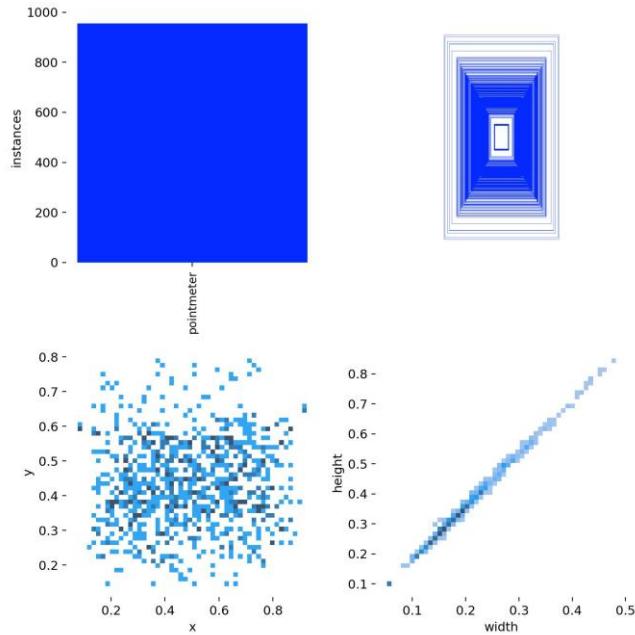


图 3-7 指针式仪表表盘检测训练数据集标签统计与可视化

以下展示了训练集中的图片示例（图 3-8），如图所示，训练数据集中同时存在单指针仪表和多个指针仪表的情况，较好的复现了实际使用中的较复杂情况，用此数据集训练出来的模型应会具有更强的泛化性能。

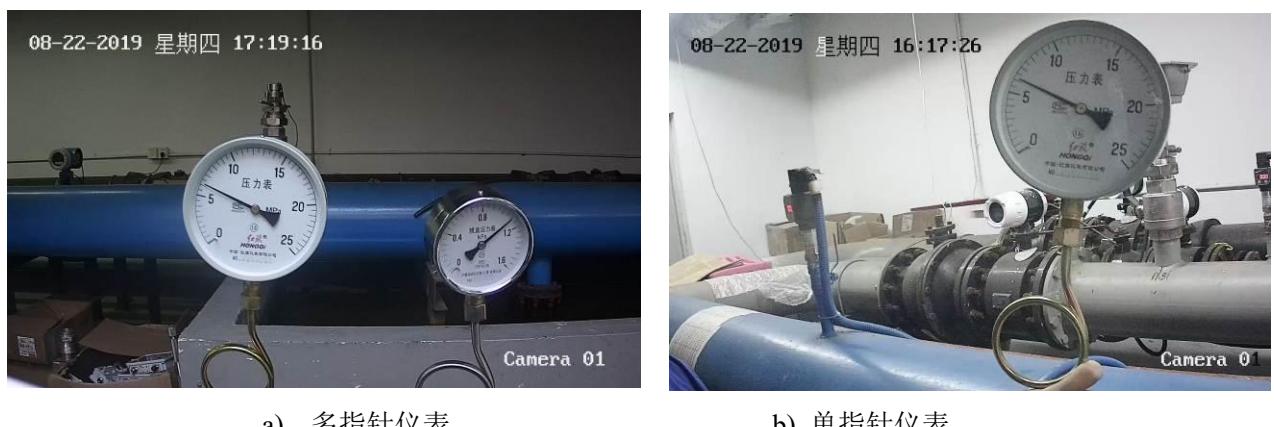


图 3-8 指针式仪表表盘检测训练数据集图像示例

如图 3-9, 图 3-10 所示，每个对应的.txt 标注文件都记录了每张图像的标注信息，格式遵循 YOL

标注标准。参数是 YOLO 的原生格式，包括类别、中心坐标 (x, y)、宽 (w) 和高 (h)。



图 3-9 指针式仪表表盘检测训练数据集图像

```
0 0.269357 0.439302 0.11715 0.201644
0 0.536985 0.539238 0.180853 0.322415
0 0.788894 0.341363 0.054157 0.099167
0 0.777656 0.596324 0.057342 0.100219
```

图 3-10 指针式仪表表盘检测训练数据集图像对应标注示例

3.4 指针式仪表特征识别模型训练数据集解释

(数据集来源：<https://github.com/zhahoi/Nanodet-YoloV8-Pose-MeterReader>)

指针式仪表特征识别训练数据集提供了一个包含 2216 张标注完整的.jpg 图像及其对应的标注文件集合，并将整个数据集按照常规比例 train:val = 4:1 进行了划分。将指针区域标记为“pointer”，刻度左起区域标注为“left”，刻度右终区域标注为“right”。观察下方指针式仪表特征识别训练数据集标签统计与可视化的图像（图 3-11）后发现，此类别实例有超过 1750+ 的数量，证明数据量较为充分。

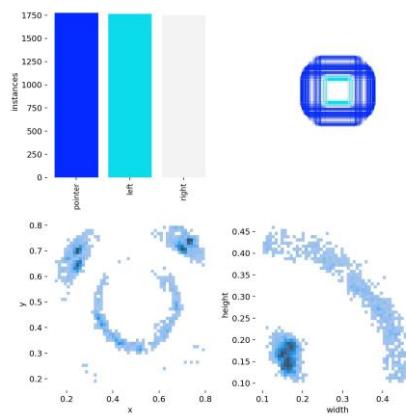


图 3-11 指针式仪表特征识别训练数据集标签统计与可视化

如图 3-12 所示，数据集图像的标注共分为 3 个区域，4 个关键点，分别是：指针区域，左刻度起始区域，右刻度终止区域，指针中心点，指针指向点，左刻度起始点，右刻度终止点。



图 3-12 指针式仪表特征识别训练数据集标注示例

3.5 本章小结

本章介绍了用于训练四类模型的仪表图像数据集，包括数显仪表数显区域检测、数显仪表示数识别、指针式仪表表盘检测以及指针式仪表特征识别。通过对数据集来源、规模、标注方式、数据划分策略以及可视化分析的详细说明，为后续模型的训练与评估奠定了坚实的数据基础。

数显仪表数显区域检测数据集提供了 2680 张高质量标注图像，并通过图像增强手段提升了模型的鲁棒性；标注信息包含矩形框及四角点坐标，能有效支持高精度定位任务；其数显仪表示数识别数据集覆盖 12 类字符，包含符号组合等复杂读数形式，适用于训练能够识别数字与符号组合关系的识别模型；指针式仪表表盘检测数据集涵盖多种结构类型，充分反映了实际应用场景的复杂性，标注框集中分布也有利于模型快速学习关键特征；指针式仪表特征识别数据集不仅包含丰富的区域标注（指针、刻度区域），还包括多个关键点标注（如指针中心点和指向点），为后续的姿态估计与读数方向判断提供了关键支持。

接下来的章节将基于这些数据集展开模型设计、训练与性能评估工作。

第四章 基于深度学习的仪表示数识别系统设计

4.1 YOLOv8 模型尺寸选择

在本项目中，选用 Ultralytics 发布的 YOLOv8n 作为目标检测模型，并在本地环境下完成训练与调优工作。虽然配备 NVIDIA RTX 3070 显卡，具备一定的图形计算能力，但在资源方面仍有限。因此，选择 YOLOv8n 模型被认为是基于性能与资源消耗之间权衡后的明智决策。

YOLOv8n 为 YOLOv8 系列中最轻量的版本，仅包含约 3.2M 的可训练参数和 8.7 GFLOPs 的计算量（以 640×640 输入尺寸为例），在确保基本检测精度的同时显著降低了对计算资源的依赖。相比 YOLOv8m/l/x 等大型模型，YOLOv8n 可在本地硬件上实现更快的训练迭代、更低的显存占用和更短的开发周期，尤其适用于模型结构调试、超参数验证以及小规模数据集实验等任务场景。此外，YOLOv8n 模型结构完整，具备良好的泛化能力，对于轻量级部署场景亦具有较高实用价值。

因此，在本地环境下基于 RTX 3070 的笔记本进行 YOLOv8n 模型的训练，被认为是在有限硬件资源下实现高效开发与实验迭代的合理选择。

以下为 YOLOv8 各个尺寸模型对比：

表 4-1 YOLOv8 各尺寸模型对比

模型版本	参数量	计算量(GFLOPs)	推理速度(ms, RTX 3090)*	mAP@0.5:0.95 (COCO)*
YOLOv8n	3.2M	8.7GFLOPs	2.3ms	37.3
YOLOv8s	11.2M	28.6GFLOPs	4.2ms	44.9
YOLOv8m	25.9M	78.9GFLOPs	8.4ms	50.2
YOLOv8l	43.7M	165.2GFLOPs	12.1ms	52.9
YOLOv8x	68.2M	257.8GFLOPs	16.4ms	53.9

4.2 数显式仪表读数系统设计

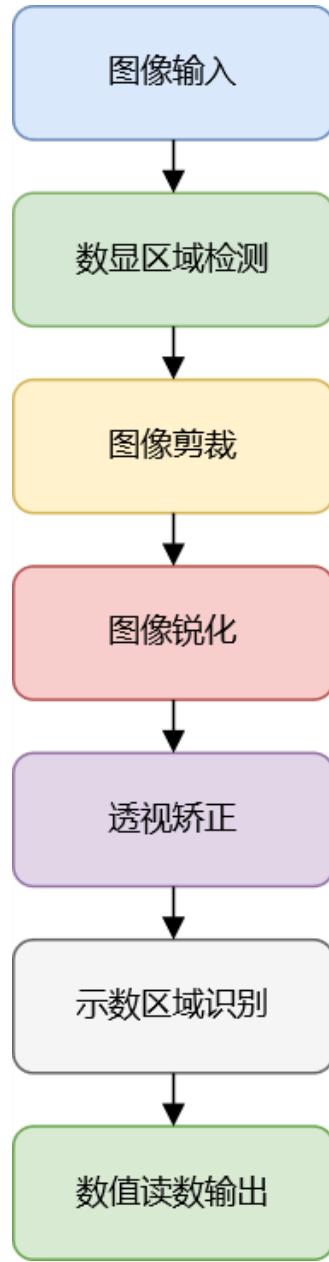


图 4-1 数显式仪表读数系统流程图

为了实现对数显式仪表的自动读数，本系统设计了一套完整的图像处理与识别流程（如图 4-1 所示）。首先，通过摄像头采集包含仪表的原始图像。接下来，利用经数显式仪表数显区域训练数据集训练后的 YOLOv8n 模型对图像中的数显区域进行精确定位。完成检测后，系统对该区域进行图像剪裁，以剔除无关背景信息，保留关键区域。随后，为提升图像的清晰度和识别准确性，进行图像锐化处理，以增强数字边缘的对比度。

考虑到拍摄角度可能存在倾斜或透视畸变，系统进一步对图像进行透视矫正，确保数显区域呈正视角度，便于后续识别。经过预处理后的图像将被输入至示数识别模块。

该模块通过经数显式仪表示数识别训练数据集训练后的 YOLOv8n 模型对数字区域进行识别，提取出清晰、准确的数值。

最终，系统将识别结果进行解析并输出，实现对仪表读数的自动获取。

4.2.1 数显仪表读数区域识别

本模块的主要任务是将原始输入数显仪表的示数区域精准定位，由于拍摄的角度、背景，光线复杂多变，因此使用鲁棒性强的 YOLOv8 模型作为本模块的目标检测模型。

通过此数显仪表读数区域检测模型，检测输出的数显读数区域将记为：

$$B = \{(x_i, y_i, w_i, h_i)\}_{i=1}^N \quad (12)$$

其中 (x_i, y_i) 表示第 i 个边界框的左上角坐标， w_i, h_i 则为边界框的宽和高。

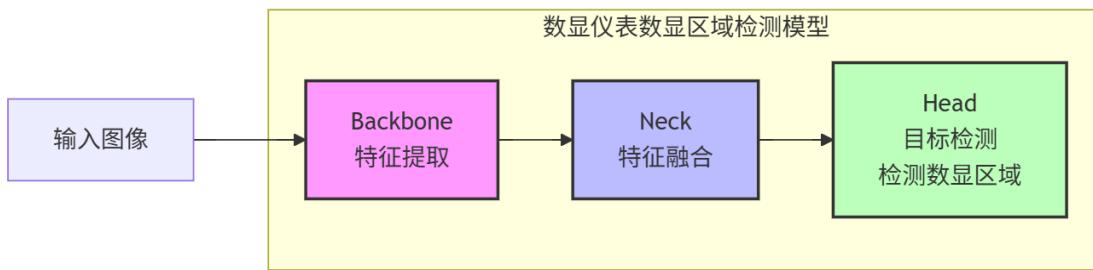


图 4-2 数显仪表数显区域检测模型架构

4.2.2 数显仪表读数区域处理

本模块主要对上一个模块检测到的示数区域进行图像的预处理，包括裁剪，锐化以及透视矫正，从而优化图像的质量，以提高后续数字识别的精度。

当数显仪表读数区域检测模型检测出数显区域后，系统自动将该区域剪裁出来以剔除无关背景，并采用非线性锐化算法（Unsharp Mask）来提升数字边缘清晰度：

$$\text{Sharpened} = (1+\alpha) \cdot I - \alpha \cdot G(I) \quad (13)$$

而数显仪表的读数区域通常呈矩形布局，因此可通过轮廓拟合与透视变换恢复其正视图像。核心步骤如下：使用 Canny 算子提取图像边缘；检测外部轮廓并使用 approxPolyDP 近似为四边形；若找到符合条件的四边形，则视为读数区域；应用透视变换恢复矩形。

透视变换公式如下：

$$\begin{bmatrix} x' \\ y' \\ w' \end{bmatrix} = \begin{bmatrix} p_{11} & p_{12} & p_{13} \\ p_{21} & p_{22} & p_{23} \\ p_{31} & p_{32} & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (14)$$

通过四对点的对应关系可唯一确定单应矩阵 H , 再用 `cv2.getPerspectiveTransform + cv2.warpPerspective` 实现变换。

4.2.3 数显仪表示数识别

该模块对处理后的图像进行数字识别, 通过另一个训练好的基于 YOLOv8n 的数显式仪表示数识别模型精确定位和分类每一个数字 (“1”, “2”, “3”, “4”, “5”, “6”, “7”, “8”, “9”) 以及特殊符号 (负号 “-” 以及小数点 “.”)。得到输出结果为:

$$D = \{(x_j, y_j, w_j, h_j, c_j)\}_{j=1}^M \quad (15)$$

其中 (x_j, y_j, w_j, h_j) , c_j 为示数分类的结果。

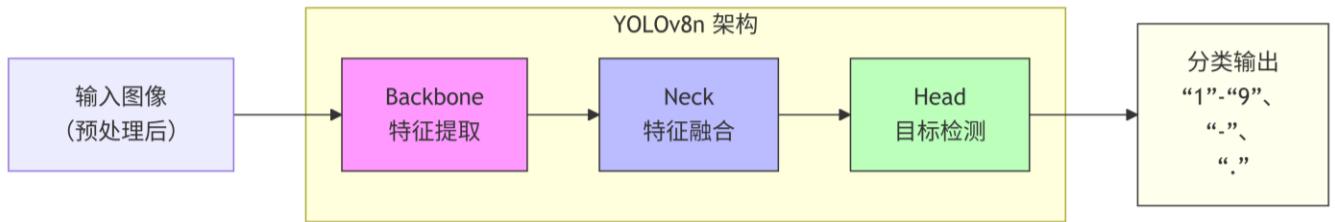


图 4-3 数显式仪表示数识别模型架构

4.2.4 数显仪表示数读数

此模块将根据识别模块输出的读数位置和读数类别进行排列组合, 通过数值组合公式处理, 获得最终的读数结果:

$$Reading = (-1)^p \sum_{j=1}^M c_j \cdot 10^{M-j-d} \quad (16)$$

其中 d 表示小数点的位置, p 表示是否检测到负号 “-” 并且是否其在第一位 (若是 $p=1$, 否则 $p=0$)。

4.3 指针式仪表读数系统设计

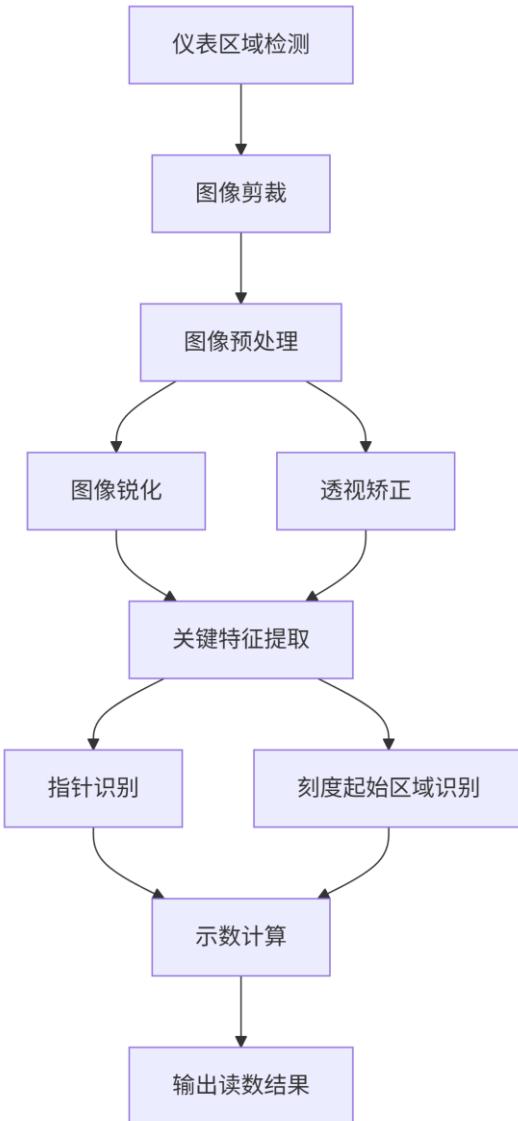


图 4-4 指针式仪表读数系统流程图

指针式仪表读数系统的主要功能是实现对指针式仪表示数的自动读取。整体流程如图 3-4 所示，系统主要包括仪表表盘区域检测、图像剪裁与预处理（包括锐化和透视矫正）、关键特征提取（指针与刻度始末区域识别）、以及最终的示数计算等模块。各模块之间相互配合，构成一个端到端的指针式仪表读数系统。

4.3.1 指针式仪表表盘检测

在本模块中，采用经指针式仪表表盘检测训练数据集训练后的 YOLOv8n 进行部署。

该模型在本项目中用于对输入图像中的指针式仪表表盘进行精确定位，并输出其边界框坐标，为后续图像裁剪与读数计算提供依据。

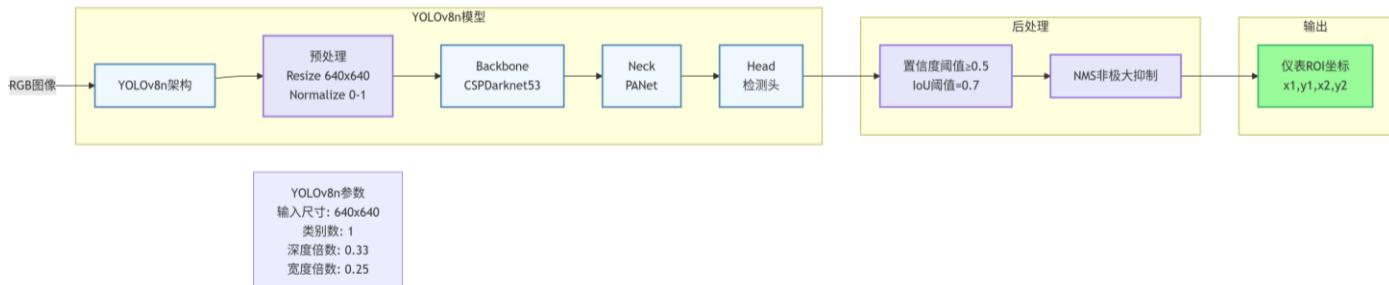


图 4-5 指针式仪表表盘检测流程图

该模型接收的输入为大小为 $640 \times 640 \times 3$ 的 RGB 图像。输出为形如：

$$Output = [x, y, w, h, objectness, c] \quad (17)$$

其中，(x,y)是边界框中心坐标，(w,h)是宽高，objectness 表示该框为目标的概率，c 是指针式仪表表盘的置信度。

4.3.2 指针式仪表表盘区域处理

为了提高指针式仪表图像后续指针检测与读数识别的精度，需要对裁切后的指针仪表表盘进行图像增强与椭圆畸变校正处理。下面是该模块的设计思路与具体方法。

由于表盘图像可能存在光照不均、对比度低、边缘模糊等问题，这些因素都有可能会影响后续轮廓提取与椭圆拟合的鲁棒性。因此，首先对图像进行锐化与对比度提升处理。本文采用经典的拉普拉斯锐化核增强图像边缘，使表盘轮廓更清晰：

$$K_{sharpen} = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 9 & -1 \\ -1 & -1 & -1 \end{bmatrix} \quad (18)$$

再利用 OpenCV 的 filter2D 实现卷积操作。

锐化后将锐化后的图像转换为 LAB 空间，仅对亮度通道 L 应用 CLAHE（局部自适应直方图均衡化）提升局部对比度：

$$L' = CLAHE(L), \quad I_{enhanced} = LAB'(L', A, B) \quad (19)$$

此外，由于在实际采集图像中，表盘由于拍摄角度偏差常表现为椭圆形。所以一般需对椭圆进行拟合并计算仿射变换矩阵，将其还原为正圆，便于后续图像校准与关键区域提取。

设拟合后的椭圆参数为：椭圆中心点：(x_c,y_c);长轴与短轴：d₁,d₂;旋转角度：θ

若 d₁>d₂，则需在 Y 方向进行缩放：

$$s = \frac{d_1}{d_2} \quad |(20)$$

旋转校正矩阵为：

$$R = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \quad |(21)$$

缩放矩阵（以长轴为基准）为：

$$S_y = \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{s} \end{bmatrix} \quad |(22)$$

仿射变换组合后，使用 OpenCV 中的 warpAffine 实现图像的旋转与缩放，从而将椭圆还原为标准圆形表盘。

4.3.3 指针式仪表特征识别

在本模块中，采用经指针式仪表特征识别训练数据集训练后的 YOLOv8pose 模型进行部署。该模型在本项目中用于对输入指针式仪表表盘中的指针仪表的指针框，指针的中心点，指针头两个关键点，刻度开始区域框，刻度开始点，刻度阶结束区域框和刻度结束点进行精确定位，并输出其边界框坐标或点坐标，为后续图像裁剪与读数计算提供依据。

4.3.4 指针式仪表示数读数

这个模块是指针式仪表读数系统中最核心的模块。该模块该系统实现了基于 YOLOv8 的多模型检测与姿态估计，用于从图像中自动读取指针仪表的读数本章小结

首先需获取如下结构的空间位置：指针中心点与指针尖端点（由 YOLOv8-Pose 检测）；刻度起始点与刻度终止点（由 YOLOv8-Pose 检测）；刻度始末区域框与终止区域框（由 YOLOv8-Pose 检测，用于推理量程）。

采用训练好的 YOLOv8 模型进行推理，得到检测框 result.boxes 和关键点 result.keypoints。将关键点按类别分类提取，分别存储为：class1_kp1 = 指针中心点；class1_kp2 = 指针尖端点；class2_kp = 刻度始末点；class3_kp = 刻度终止点。

同时，利用先前的数显仪表示数识别模型分别检测刻度起始区域框与刻度终止区域框，获取其对应数值 `start_value` 与 `end_value`，由此推导出量程：

$$\text{range_value} = \text{end_value} - \text{start_value} \quad (23)$$

同时，为方便角度计算，将指针中心点 `class1_kp1` 作为原点，所有关键点坐标统一进行平移变换：

$$\begin{aligned}\overrightarrow{V_{pointer}} &= \overrightarrow{P_{pointer}} - \overrightarrow{P_{center}} \\ \overrightarrow{V_{start}} &= \overrightarrow{P_{start}} - \overrightarrow{P_{center}} \\ \overrightarrow{V_{end}} &= \overrightarrow{P_{end}} - \overrightarrow{P_{center}}\end{aligned} \quad (24)$$

为获得角度，我们使用二维向量夹角的反余弦公式（或 `atan2` 差值法）计算指针方向相对于刻度始末方向的夹角，以及整个刻度扇区的夹角：

$$\begin{aligned}\theta_{pointer} &= \text{angle}(\overrightarrow{V_{start}}, \overrightarrow{V_{pointer}}) = \arctan2(y_{pointer}, x_{pointer}) - \arctan2(y_{start}, x_{start}) \\ \theta_{scale} &= \text{angle}(\overrightarrow{V_{start}}, \overrightarrow{V_{end}}) = \arctan2(y_{end}, x_{end}) - \arctan2(y_{start}, x_{start})\end{aligned} \quad (25)$$

为保证角度为正值并适应超过 180° 的情况，对角度进行标准化处理：

$$\theta = (\theta + 360^\circ) \bmod 360^\circ \quad (26)$$

获得角度后，可通过角度在扇区角度内的相对比例，计算指针所指读数值：

$$\text{reading} = \text{start_value} + \left(\frac{\theta_{pointer}}{\theta_{scale}} \right) \times (\text{end_value} - \text{start_value}) \quad (27)$$

（该公式基于读数值线性映射于角度范围内的假设，即指针在刻度起点与终点间均匀划分量程）

4.4 本章小结

本章分别设计了数显式和指针式两类仪表的图像处理与识别流程。在模型选择方面，基于本地 RTX 3070 硬件条件，选用轻量级的 YOLOv8n 作为目标检测模型，其参数量仅为 3.2M，计算量为 8.7GFLOPs，兼顾性能与资源效率，适合模型调试与快速迭代。

在数显式仪表读数系统中，系统首先通过数显式仪表数显区域检测模型定位数显区域，并对该区域进行裁剪、锐化与透视矫正，以提升图像质量。随后，利用数显式仪表示数识别模型对数字与特殊符号进行识别，并结合位置信息完成最终读数解析。

在指针式仪表读数系统中，系统通过指针式仪表表盘检测模型检测表盘区域，并对其进行图像增强、锐化及椭圆畸变校正。利用拉普拉斯锐化和 CLAHE 算法提升边缘清晰

度和对比度，随后通过椭圆拟合与仿射变换将图像恢复为正圆，为后续关键区域提取与示数计算提供基础。接着使用指针式仪表特征识别（指针与刻度始末区域）模型对指针仪表的指针框，指针的中心点，指针头两个关键点，刻度开始区域框，刻度开始点，刻度阶结束区域框和刻度结束点进行精确定位。最后通过师叔计算模块获得精准的读数。

第五章 数显仪表示数识别系统实验结果与分析

5.1 数显式仪表数显区域检测模型

和指针式仪表相同，数显式仪表读数核心步骤的第一步也是是在繁杂的场景中精准识别并裁切出整个数显区域，同样根据第三章的选择构建专属的指针式仪表表盘检测数据集训练一个 YOLOv8n 模型，以下是对该模型训练中各步骤的解释与分析。

5.1.1 模型训练过程

5.1.1.1 训练文件配置

同样选用轻量级的 YOLOv8n (nano) 模型作为基线网络，加载其预训练权重以提升收敛速度。训练共进行 100 个 epoch，图像输入尺寸设为 640×640 ，批次大小为 16。为确保结果具有可重复性，固定随机种子为 0，并启用确定性训练模式。其他基础训练配置，优化器与损失函数设置，以及数据增强策略与指针式仪表表盘检测模型的训练配置基本相同，故不作过多的阐释。

5.1.1.2 模型训练结果分析

模型训练完成后，得到训练结果，以下为模型训练结果的具体分析：

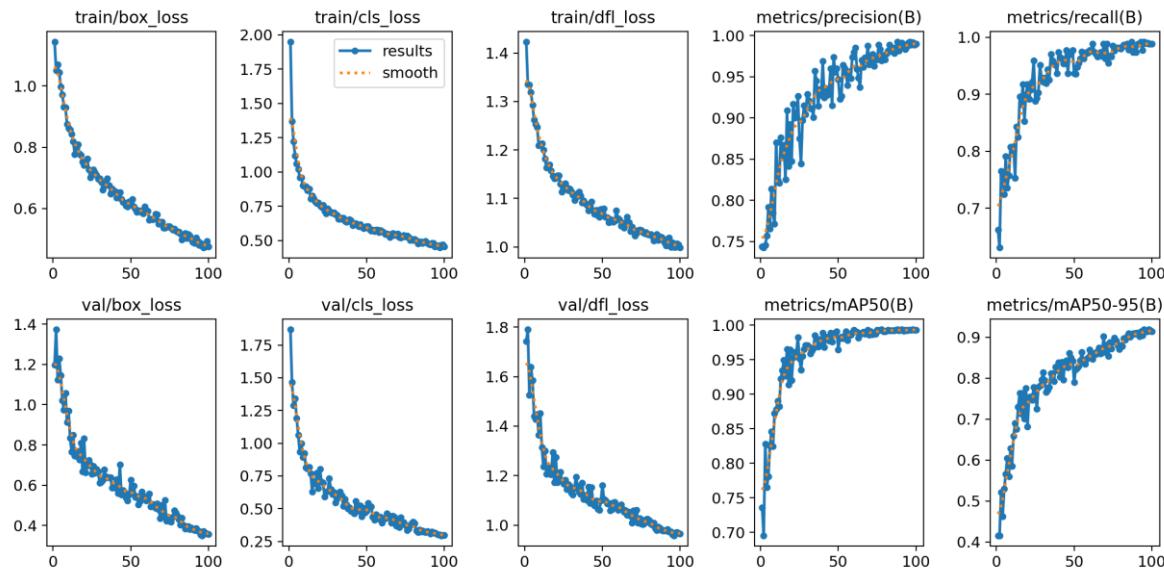


图 5-1 数显式仪表数显区域检测模型训练结果

1.训练损失分析 (train/box_loss、train/cls_loss、train/dfl_loss):

边框损失（train/box_loss）在训练过程中呈现出显著的下降趋势，表明模型在目标定位方面的性能持续提升，损失逐步收敛，体现出良好的学习效果。

类别损失（train/cls_loss）快速下降并趋于稳定，说明模型在目标分类任务上已获得有效的学习，分类能力不断增强。

分布焦点损失（train/dfl_loss）在初始阶段数值较高，但随着训练的推进，损失持续下降并趋于平稳，反映出模型在关键点定位任务上不断优化。

2. 验证损失分析（val/box_loss、val/cls_loss、val/dfl_loss）：

边框损失（val/box_loss）在验证集上初期同样偏高，随后呈下降趋势，尽管中后期略有波动，整体仍表现出持续优化的态势。波动可能归因于验证集样本的多样性或模型泛化能力的提升空间。

类别损失（val/cls_loss）表现出类似的下降趋势，虽存在轻微波动，但整体呈现稳定下滑，说明模型在未见样本上的分类效果逐步改善。

分布焦点损失（val/dfl_loss）下降趋势明显，并在训练后期趋于稳定，反映出模型在关键点预测任务中的鲁棒性有所增强。

3. 评估指标分析（metrics/precision(B)、metrics/recall(B)、metrics/mAP50(B)、metrics/mAP50-95(B)）

精度（metrics/precision(B)）从训练初期即维持在较高水平，后续训练过程中始终表现稳定，表明模型在预测时有效抑制了假阳性（False Positives）。

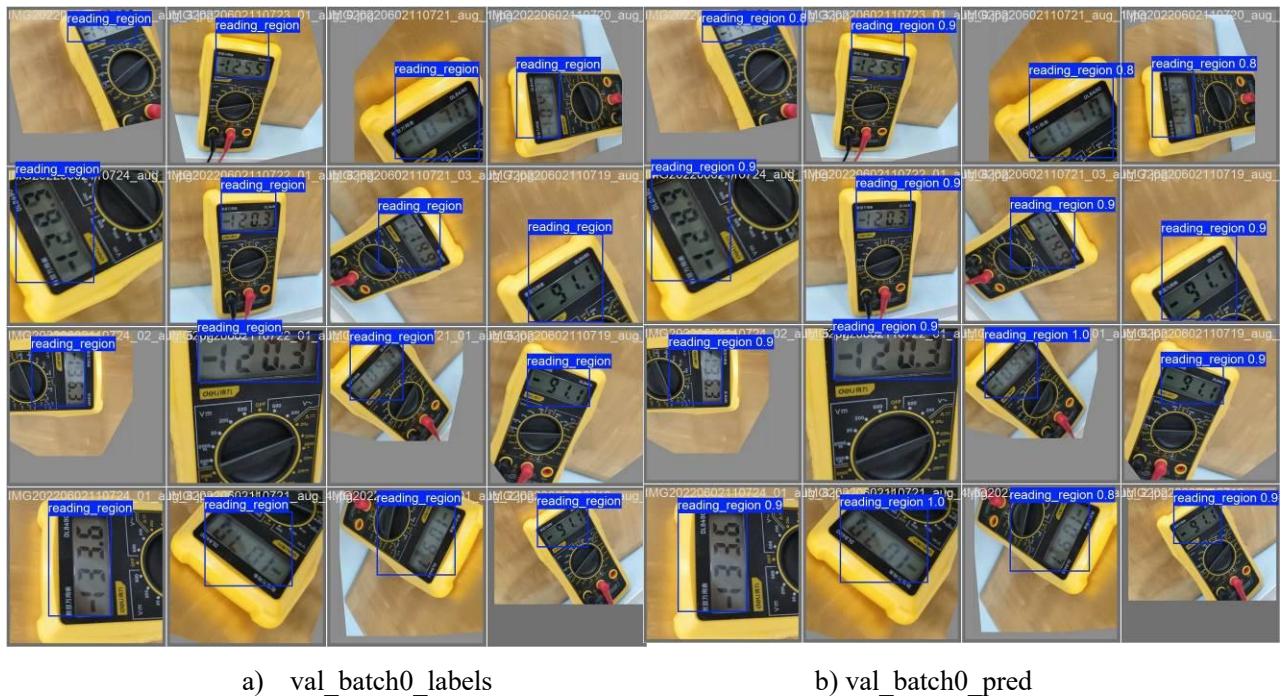
召回率（metrics/recall(B)）在初期偏低，随着训练不断深入，迅速上升并接近 1，说明模型对真实目标的检测能力大幅增强，具有良好的目标检出率。

均精度（metrics/mAP50(B)）在 IoU 阈值为 0.5 的情况下稳步上升，最终接近 1，表明模型在该阈值下具有极高的检测精度。

综合平均精度（metrics/mAP50-95(B)）在多个 IoU 阈值下均持续提升，虽略低于 mAP50，但整体表现优异，说明模型在高 IoU 要求下仍具备较强的鲁棒性与泛化能力。

所以综上所述，该模型在训练和验证阶段均表现出较好的收敛性与稳定性，训练损失与验证损失均呈下降趋势，反映出模型在目标检测任务中，尤其在目标定位、分类及关键点预测方面具有显著的性能提升。各项评估指标均达到较高水平，进一步验证了模型的检测精度与泛化能力。

5.1.1.3 模型泛化性能分析



a) val_batch0_labels

b) val_batch0_pred

图 5-2 数显式仪表表盘检测模型验证集对照

如图 5-2 所示，该模型目前在验证集上的测试效果已经非常良好，为了进一步测试模型在复杂环境中的鲁棒性，又构建了一个拥有 123 例的测试集（示例如图 5-3 所示），发现能准确识别其中 114 例，识别准确率高达 92.68%。



a) 测试实例

b) 测试结果

图 5-3 数显式仪表表盘检测模型测试集示例

5.2 数显式仪表示数识别模型

除了数显仪表示数区域检测，数显式仪表读数的另一个核心步骤的就是在处理后的示数区域中准确识别出电子示数，同样根据第三章的选择构建专属的数显式仪表示数识别数据集训练一个 YOLOv8n 模型，以下是对该模型训练中各步骤的解释与分析。

5.2.1 模型训练过程

5.2.1.1 训练文件配置

同样选用轻量级的 YOLOv8n (nano) 模型作为基线网络，加载其预训练权重以提升收敛速度。训练轮数为 150 轮，采用 640×640 的统一图像输入尺寸，批大小为 16，训练过程中开启自动混合精度 (AMP) 以提升训练效率。所有训练过程均使用固定随机种子以保证结果可复现，同时启用了 deterministic 训练与数据增强中的 mosaic 拼图。其他基础训练配置，优化器与损失函数设置，以及数据增强策略与指针式仪表表盘检测模型的训练配置基本相同，故不作过多的阐释。

5.2.1.2 模型训练结果分析

模型训练完成后，得到训练结果，以下为模型训练结果的具体分析：

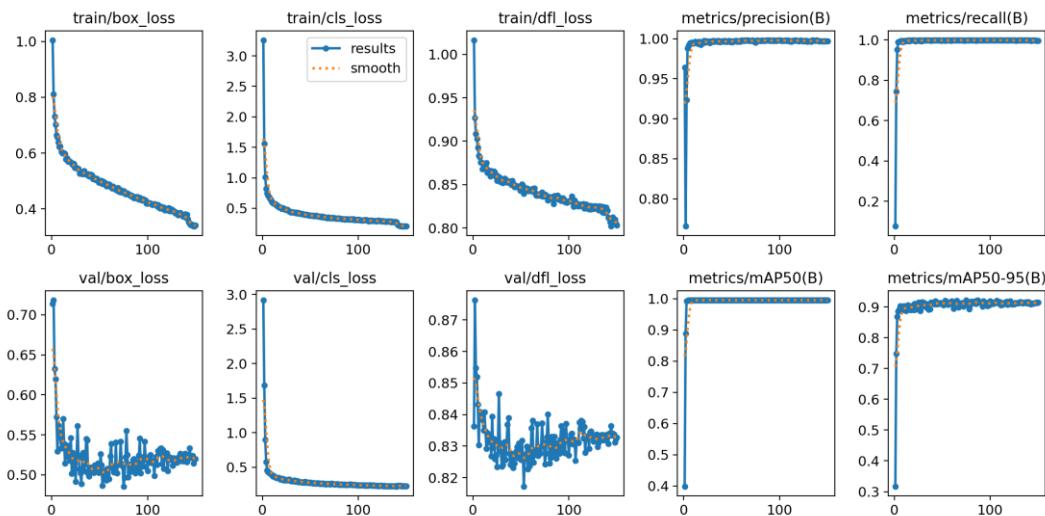


图 5-4 数显式仪表示数识别模型训练结果

表 5-1 训练损失分析表

train/box_loss	从训练过程中可观察到，边框损失在初期迅速下降，并在后期趋于
----------------	-------------------------------

	平稳，表明模型在目标定位方面已逐渐收敛，具备较强的拟合能力。
train/cls_loss	分类损失呈现出相似的下降趋势，初始阶段下降速度较快，后期波动较小，说明模型在类别识别能力方面得到了显著提升。
train/cls_loss	分布式焦点损失（Distribution Focal Loss）同样呈现出明显的下降趋势，反映出模型在目标边界细化（如回归精度或关键点定位）方面不断优化。

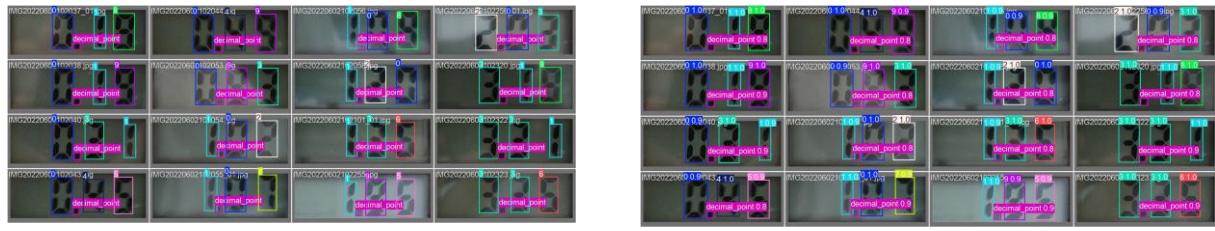
表 5-2 验证损失分析表

val/box_loss	验证集的边框损失在训练初期相对较高，随着训练进展逐步下降，但整体波动略大，可能反映出验证集目标形态更为复杂或模型对新样本的泛化能力仍在提升中。
val/cls_loss	类别损失在前期下降明显，但中后期存在一定波动，可能与模型对特定类别的过拟合或验证集类别分布不均有关。
val/dfl_loss	分布式焦点损失在验证集上的变化趋势略为不稳定，尤其在训练后期出现一定程度的波动，提示在关键点或边界位置的泛化性能仍有优化空间。

此外平均精度在 IoU 阈值为 0.5 时的平均精度（mAP50）表现出持续上升趋势；而在更严格的 IoU 范围（0.5 到 0.95）下的 mAP50-95 略低，但整体呈上升态势，表明模型不仅在粗粒度检测下表现良好，在精细检测场景中亦具备较强的稳定性。

综合训练与验证过程的各项指标可见，模型在定位、分类与边界回归等方面均表现出良好的收敛性与性能提升趋势。尽管验证阶段部分损失存在波动，但整体训练过程稳定、收敛迅速，说明模型具备较强的学习能力和目标检测能力。各项评估指标的持续提升进一步证明了模型在真实场景中具备良好的鲁棒性与泛化性能。。

5.2.1.3 模型泛化性能分析



a) val_batch0_labels

b) val_batch0_pred

图 5-5 数显式仪表示数识别模型验证集对照

如图 5-5 所示，该模型目前在验证集上的测试效果已经非常良好，为了进一步测试模型在复杂环境中的鲁棒性，又构建了一个拥有 100 例的测试集（示例如图 5-6 所示），发现能准确识别其中 88 例，识别准确率高达 88%，这预示着可能还要做前处理继续提高模型精度。



a) 测试实例

b) 测试结果

图 5-6 指针式仪表表盘检测模型测试集示例

5.3 数显式仪表读数

本节将介绍数显式仪表图像的自动读数各流程结果分析，包括读数区域的识别、图像预处理、字符识别以及最终读数提取等关键环节。

5.3.1 数显式仪表表盘检测结果

本阶段旨在从原始图像中准确定位出仪表读数区域。使用前文训练的数显式仪表数显区域检测模型进行区域识别，输出包括目标框位置、类别与置信度。



a) 数显仪表原图

b) 识别区域标注结果

图 5-7 数显仪表原图与识别区域标注结果

表 5-3 识别区域位置信息表

图像	框坐标 (x, y, w, h)	类别	置信度
	(1298.43, 3.37, 1692.08, 1028.29)	reading_region	0.72
	(151.72, 98.53, 476.01, 380.82)	reading_region	0.81
.....			

由之前的模型分析可以得知，大部分图像中识别区域能够准确覆盖数显窗口，但在少数情况下（如图像倾斜严重或背景干扰强烈）可能会存在轻微偏差。而下一步将通过图像的锐化与透视变换进一步提升读数区图像的可识别性。

5.3.2 数显仪表读数区域处理结果

为了提高后续示数识别的准确率,对提取的读数区域图像进行一系列图像增强处理,包括:图像锐化、对比度增强、透视矫正。

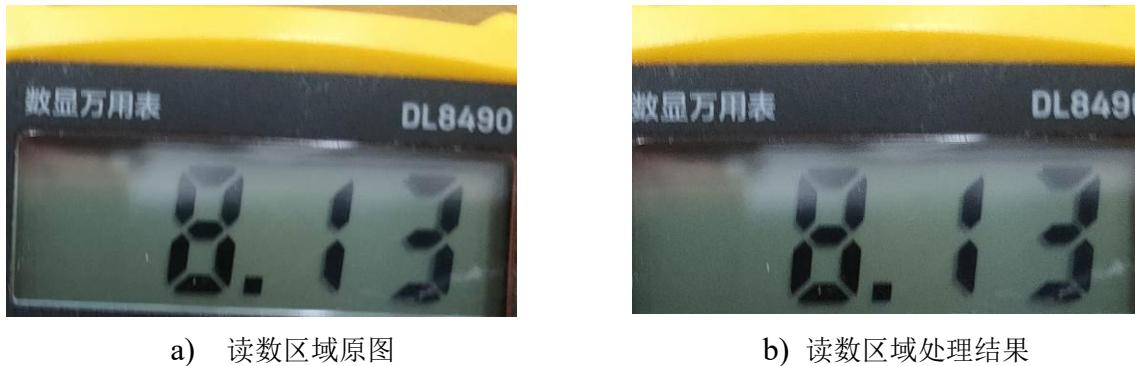


图 5-8 锐化与透视矫正后的读数区域示例

经过预处理后的图像对数字轮廓进行了增强,使字符边缘更清晰,对比度显著提升。特别是在低光或图像倾斜条件下对图像质量的提升尤为明显。

5.3.3 数显仪表示数识别结果

本阶段旨在从原始图像中准确定位出仪表读数区域。使用前文训练的数显式仪表示数识别模型进行示数的精准识别,输出包括目标框位置、类别与置信度

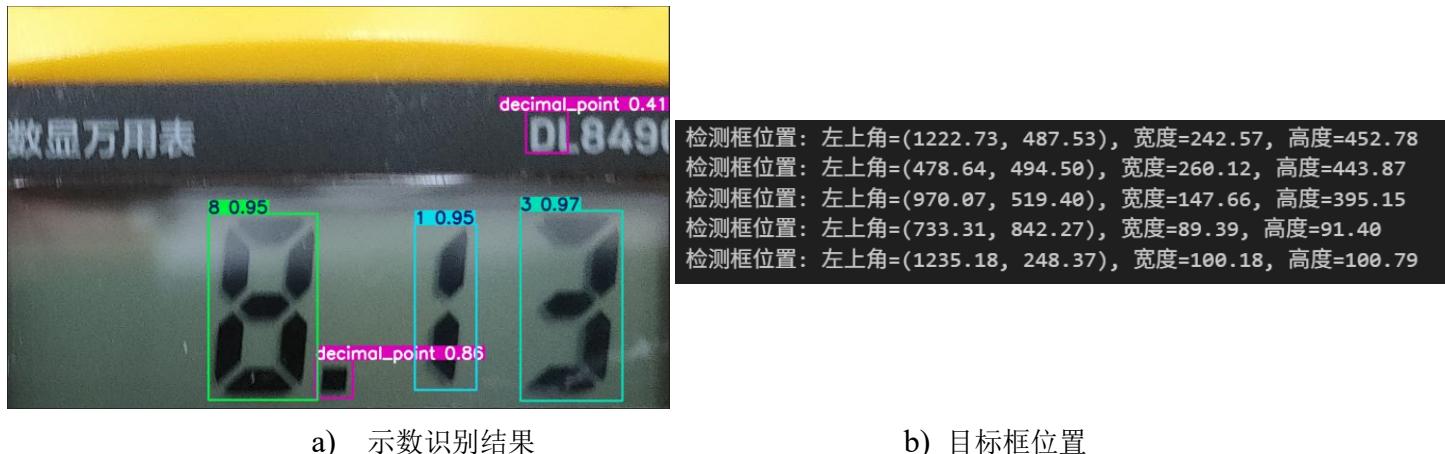


图 5-9 数显仪表示数精准识别实例

同样由之前的模型分析可以得知,大部分图像中的数字和已标注的特殊字符(“.”,“-”)能够准确覆盖数显窗口,但在少数情况下(如字符“3”与“8”在特定字体和光照下易混淆或某些仪表字体间距过窄,字符粘连)可能会存在轻微偏差。

5.3.4 数显仪表示数读数结果

识别到的字符经过读数算法处理后，将会输出为最终的读数值。



图 5-10 数显仪表示数读数结果实例

接下来在数显仪表读数测试集上进行测试，初步获得数显仪表系统的读数正确率与各个字符（“0, 1, 2, 3, 4, 5, 6, 7, 8, 9, -, .”）识别准确率。

数显仪表自动读数系统效果评估

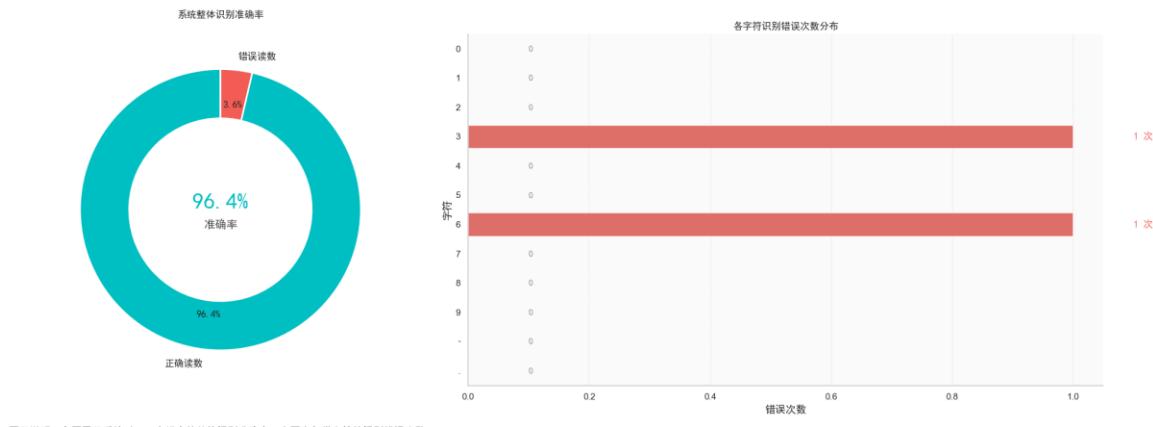


图 5-11 数显仪表自动读数系统效果评估图

在本次测试中，共输入 55 个样本，系统正确识别 53 个，错误识别 2 个，整体识别准确率高达 96.4%。从字符识别错误分布统计图中可以看出，字符“3”和“6”各发生 1 次识别错误，其余字符（包括“0 - 9、-、.”）的识别均未出现错误，即识别正确率为 100%。

进入测试结果图册发现，识别出现偏差的问题主要是在特定的光照条件下在读数区域上产生了阴影对读数的识别造成了影响。由于研究时间有限，有机会将在后续的研究过程中逐步进行优化。

5.3.5 数显仪表读数小结

本章是数显仪表图像的自动读数整个流程的结果分析，从区域检测、示数图像预处理到示数识别，构建了完整的图像读数通路。实验结果表明，该方法在常见工业图像条件下具有较高的读数准确率。后续可通过优化示数图像预处理的流程、引入自定义字符集和多模型融合进一步提高系统性能。

5.4 本章小结

本章围绕数显式仪表自动读数系统各模块实验的结果展开了详细介绍，并通过实验验证了所设计的各模块在实际应用中的有效性和可行性。

本模块使用的 2 个训练模型均达到了较高的精度：数显式仪表数显区域检测模型在测试数据集的正确率为 92.68%；数显式仪表示数识别模型在测试数据集的正确率为 88%。

数显式仪表读数系统在测试数据集的评估中，读数准确率为 96.4 满足多数工业表盘读数精度需求。

本部分各模块均通过定量实验证明了其性能。模型检测精度高、图像处理效果显著、读数结果准确，充分表明本系统具备良好的实用性和工程应用潜力。

第六章 指针仪表示数识别系统实验结果与分析

6.1 指针式仪表表盘检测模型

如第三章所阐述，指针式仪表读数核心步骤的第一步就是在繁杂的场景中精准识别并裁切出整个指针式仪表的表盘，根据第三章的选择构建专属的指针式仪表表盘检测数据集训练一个 YOLOv8n 模型，以下是对该模型训练中各步骤的解释与分析。

6.1.1 模型训练过程

6.1.1.1 训练文件配置

我们选用轻量级的 YOLOv8n (nano) 模型作为基线网络，加载其预训练权重以提升收敛速度。训练共进行 100 个 epoch，图像输入尺寸设为 640×640 ，批次大小为 16。为确保结果具有可重复性，固定随机种子为 0，并启用确定性训练模式。

表 6-1 指针式仪表表盘检测模型基本训练配置

参数项	值
模型结构	yolov8n.pt
图像尺寸	640
Epochs	100
Batch Size	16
Deterministic	True
Workers	8

优化器选择自动模式，YOLOv8 默认采用 SGD。学习率初始值设为 0.01，并采用余弦退火策略在训练后期衰减至 0.01 倍初始值。为防止训练初期梯度震荡，设定 3 个 warmup 轮次，并调节 warmup 阶段的动量与偏置学习率。

表 6-2 优化器与学习率策略

参数项	值
学习率初始值 lr0	0.01
学习率最终值 lrf	0.01

动量	0.937
权重衰减	0.0005
Warmup 轮次	3.0
Warmup 动量	0.8
Warmup 偏置学习率	0.1

本实验中使用标准的 YOLOv8 检测损失函数，由边界框损失（box）、分类损失（cls）和 DFL（分布式回归损失）组成，权重分别为 7.5、0.5 和 1.5，以平衡定位与分类精度。

表 6-3 损失函数超参数

损失项	权重
Box Loss	7.5
Class Loss	0.5
DFL Loss	1.5

此外，为提升模型的泛化能力，采用了多种数据增强策略。包括颜色扰动（HSV）、平移、缩放、翻转等几何变换；此外还启用了 Mosaic 拼图增强和 RandAugment 自动增强策略，有效扩展了训练样本的多样性。

6.1.1.2 模型训练结果分析

模型训练完成后，得到训练结果，以下为模型训练结果的具体分析：

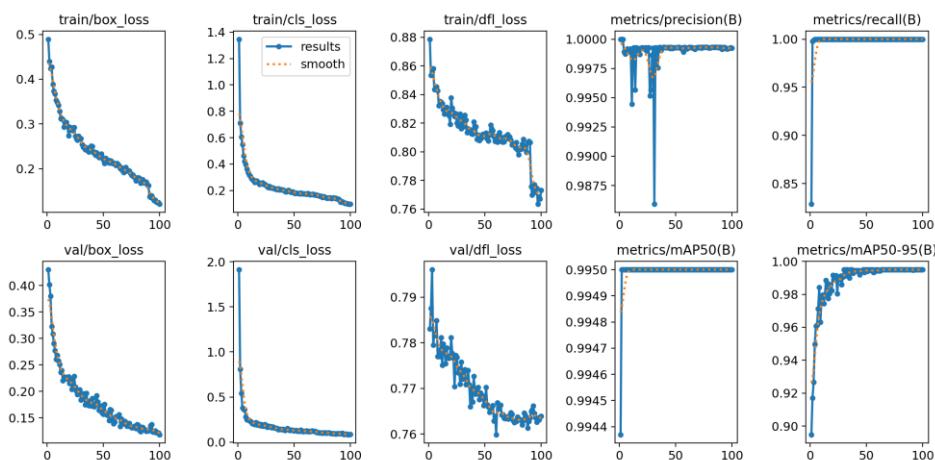


图 6-1 指针式仪表表盘检测模型训练结果

1. 损失函数分析 (Loss Curves)

表 6-4 训练集损失分析

边界框回归损失 (train/box_loss)	该损失在训练过程中持续下降，从初始约 0.5 逐步降至约 0.13，表明模型在目标位置预测方面的精度不断提升。
分类损失 (train/cls_loss)	分类损失下降速度显著，从初始约 1.3 快速收敛至 0.1 以下，反映出模型较早便掌握了对目标类别的判别能力。
分布式回归损失 (train/dfl_loss)	该损失稳定下降，最终收敛至约 0.77，说明模型在边界框细粒度定位方面的能力不断增强。

表 6-5 验证集损失分析

边界框与分类损失 (val/box_loss, val/cls_loss)	在验证集上，两项损失均呈现平滑下降趋势，最终分别收敛至约 0.12 和 0.1，说明模型在未见数据上的表现良好。
分布式回归损失 (val/dfl_loss)	分布式回归损失 (val/dfl_loss)：该损失下降趋势与训练集基本一致，整体波动较小，进一步验证了模型的泛化能力。

由表 6-4 以及表 6-5 分析结果可得，训练与验证阶段的损失曲线均呈现单调下降趋势，曲线平滑，未出现明显震荡或过拟合迹象，表明模型训练过程稳定且有效。

2. 性能指标分析 (Evaluation Metrics)

表 6-6 精度与召回率分析

精度 (Precision, metrics/precision(B))	整体维持在 0.998 以上，虽然初期存在轻微波动，但迅速趋于稳定，显示出模型具备极低的误报率。
召回率 (Recall, metrics/recall(B))	在训练初期迅速提升并稳定于 1.0，表明模型几乎检测到了所有真实目标，漏检率极低。
mAP@0.5 (metrics/mAP50(B))	在训练初期即快速达到 0.995 以上，并保持平稳，体现出模型在 IoU=0.5 条件下具有极强的检测能力。
mAP@0.5:0.95 (metrics/mAP50-95(B))	该指标逐步提升，最终接近 1.0，表明模型在更为严格的 IoU 条件下依然具备良好的检测精度与泛化性能。

由表 6-6 分析结果可得，模型在各项评估指标上均表现出色，尤其在精度、召回率及平均精度等关键性能方面接近最优水平，反映出其在实际应用中的强鲁棒性与可靠性。

由此上述分析可知，本次模型训练过程稳定，参数收敛良好，性能指标优异，验证

了模型的高效性与在未见数据上的强泛化能力。

6.1.1.3 模型泛化性能分析

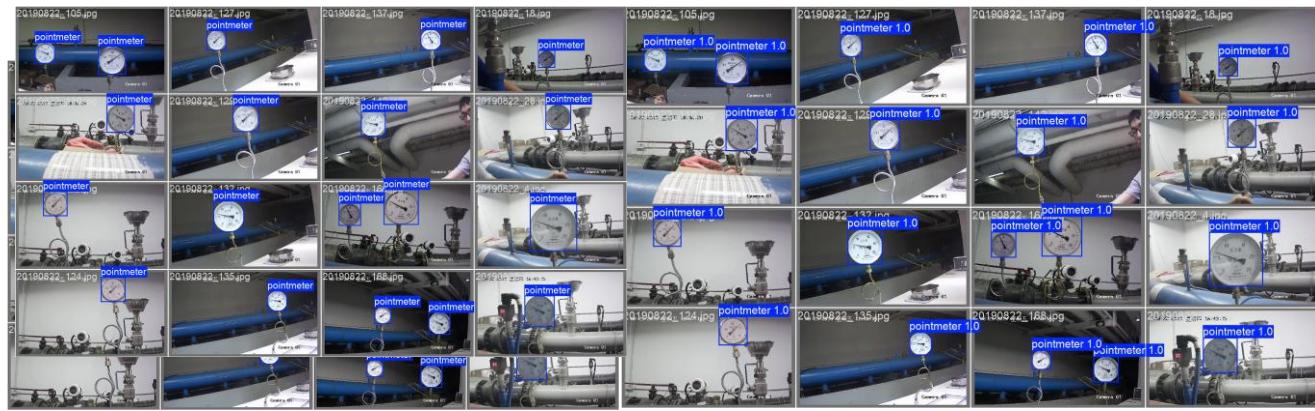


图 6-2 指针式仪表表盘检测模型验证集对照

如图 6-2 所示，该模型目前在验证集上的测试效果已经非常良好，为了进一步测试模型在复杂环境中的鲁棒性，又构建了一个拥有 100 例的测试集（示例如图 6-3 所示），发现能准确识别其中 97 例，识别准确率高达 97%。

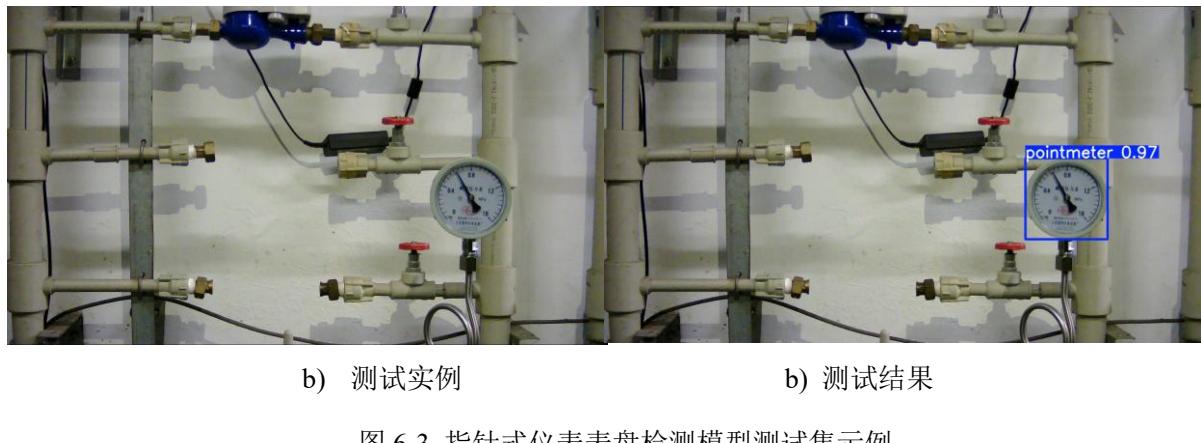


图 6-3 指针式仪表表盘检测模型测试集示例

6.2 指针式仪表特征识别（指针与刻度始末区域）模型

指针式仪表读数还有一个核心步骤就是在检测出指针表盘并进行处理后对表盘上的指针与刻度的始末区域，以便后续确定指针所在的夹角比例，以此计算得出此时的表示数。因此依然需要使用 YOLOv8 进行特征检测，以下是对该模型训练中各步骤的解释与分析。

6.2.1 模型训练过程

6.2.1.1 训练文件配置

选用轻量级的 yolov8n-pose 模型作为基线网络，加载其预训练权重以提升收敛速度。训练共进行 150 个 epoch，图像输入尺寸设为 640×640 ，批次大小为 16。为确保结果具有可重复性，固定随机种子为 0，并启用确定性训练模式。除损失函数设置略有不同（如表 6-7 所示），其他基础训练配置，优化器，以及数据增强策略与指针式仪表表盘检测模型的训练配置基本相同，故不作过多的阐释。

表 6-7 损失函数设置表

损失项	权重
Box Loss	7.5
Class Loss	0.5
DFL Loss	1.5
Pose Loss	12.0
Kobj Loss	1.0

6.2.1.2 模型训练结果分析

模型训练完成后，得到训练结果，以下为模型训练结果的具体分析：

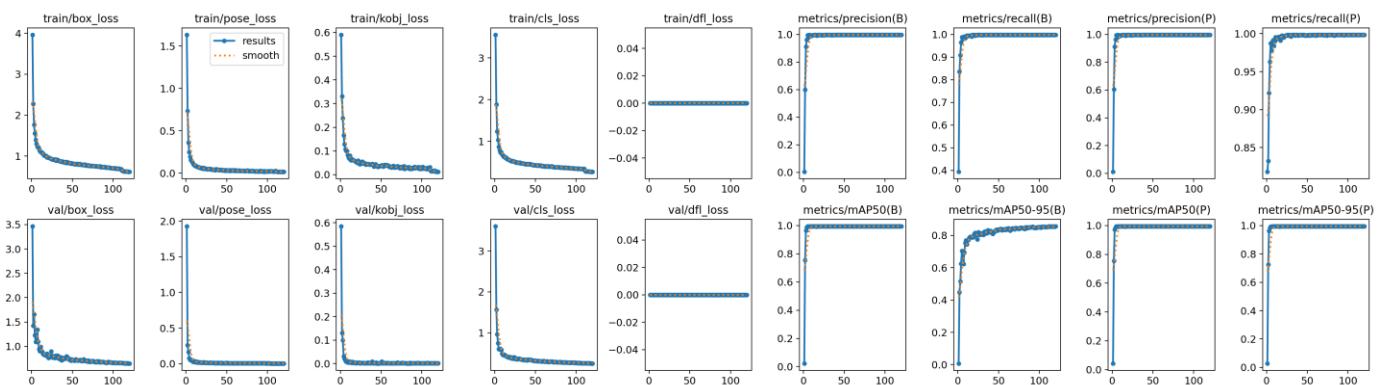


图 6-4 指针式仪表特征识别模型训练结果

训练过程中，各项损失函数均呈现良好的下降趋势，表明模型逐步收敛并持续优化：其中边框回归损失（box_loss）从约 1.2 下降至 0.5，显示出模型在边界框预测方面的精

度显著提升。姿态损失（pose_loss）快速下降并趋于 0，表明模型已较好地学习并掌握了关键点姿态特征。目标存在性损失（kobj_loss）由 0.75 下降至约 0.25，说明模型在判断目标是否存在方面的能力显著增强。分类损失（cls_loss）持续下降，最终稳定在 0.9 左右，显示出模型具备良好的分类准确性。分布焦点损失（dfl_loss）整体波动较小，稳步下降至 0.05，说明模型定位边界框细节的能力逐渐优化并收敛。

验证集上的损失变化趋势整体与训练集一致，进一步印证了模型的稳定性和泛化能力。在目标检测性能方面，模型各项指标均表现优异：精度（precision）与召回率（recall）均接近 0.997，说明模型在减少误检和漏检方面表现出色。平均精度（mAP50 与 mAP50-95）分别稳定在 0.995 以上，表明模型在不同 IoU 阈值下都具备极高的检测准确性。

从训练与验证损失曲线及性能指标来看，模型训练过程稳定、收敛良好，且具备较强的目标检测与姿态估计能力。尽管验证损失略高于训练损失，可能存在轻微过拟合，但整体泛化能力良好。各项评估指标均达到高水平，表明该模型在复杂检测任务中表现卓越。

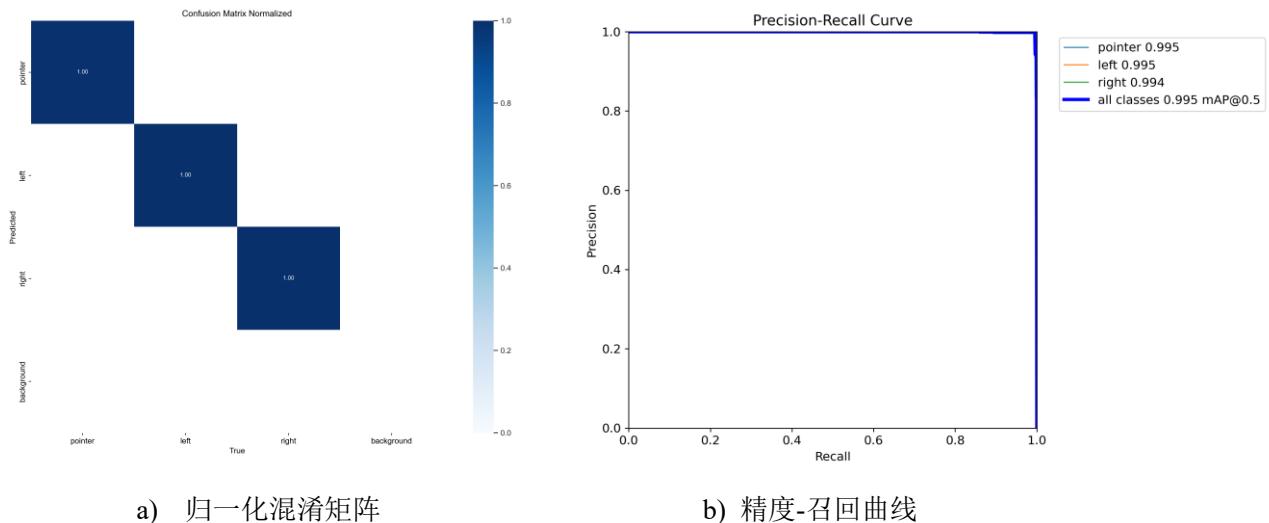


图 6-5 指针式仪表特征识别模型训练结果

如图 6-5，模型对这些类别的预测非常准确，所有类别的预测值都达到了 1.00，这意味着每个类别都完全正确分类，没有出现误分类的情况，且模型的精度和召回率都表现出色。

6.2.1.3 模型泛化性能分析

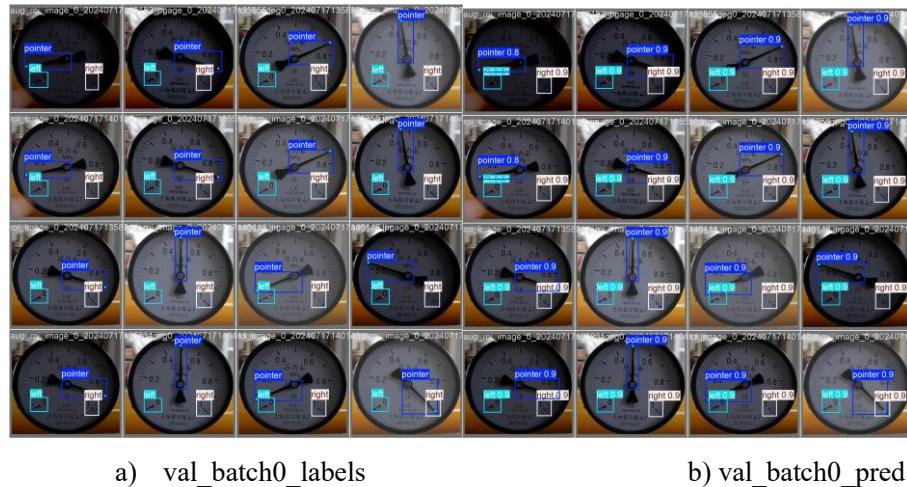


图 6-6 指针式仪表特征识别模型验证集对照

如图 6-6 所示，该模型目前在验证集上的测试效果已经非常良好，为了进一步测试模型在复杂环境中的鲁棒性，又构建了一个拥有 87 例的测试集（示例如图 6-7 所示），发现能准确识别其中 81 例，识别准确率高达 93.8%。

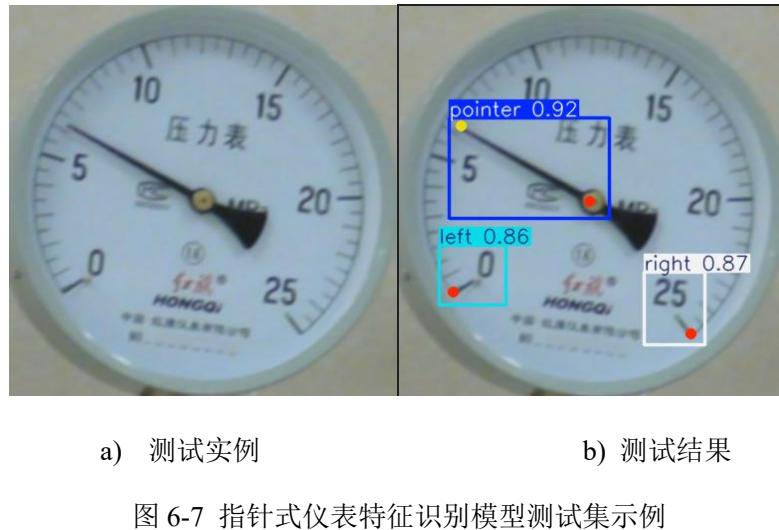


图 6-7 指针式仪表特征识别模型测试集示例

6.3 指针式仪表读数

本节将介绍指针式仪表图像的自动读数各流程结果分析，包括指针表盘的识别、表盘区域预处理、表盘特征识别（指针与刻度始末区域）以及最终读数提取等关键环节。

6.3.1 指针式仪表表盘检测结果

本阶段旨在从原始图像中准确定位出指针仪表的表盘区域。使用前文训练的数显式

仪表数显区域检测模型进行区域识别，输出包括目标框位置、类别与置信度。



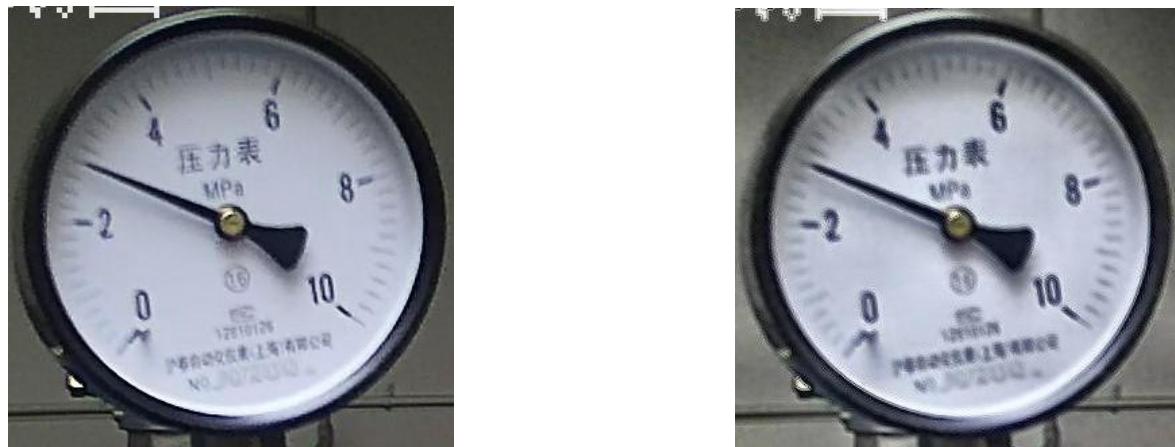
a) 指针仪表原图

b) 识别区域标注结果

图 6-8 指针仪表原图与表盘识别区域标注结果

由上文的指针式仪表表盘检测模型分析可以得知，指针式仪表表盘的识别准确率高达 97%，但在极少数情况下（如图像严重变形或背景干扰强烈）可能会存在识别不准确的情况。而下一步将通过图像增强与椭圆畸变校正处理进一步提升读数区图像的质量。

6.3.2 指针式仪表表盘区域处理结果



a) 指针仪表表盘原图

b) 图像增强与椭圆畸变校正结果

图 6-9 指针式仪表表盘区域处理结果

为提升仪表图像的质量与几何一致性，在正式读数前引入了图像增强与椭圆畸变校正两项预处理操作。由于处理结果难以量化，只能如图 6-9 举例证明这些处理在实际应用中显著提升了模型的检测精度与稳定性。

图像增强部分主要包括亮度调整、对比度增强与锐化处理，有效改善了低照度或模糊场景下仪表轮廓不清的问题，增强了指针与刻度区域的边缘特征，使得模型在弱纹理

背景中也能准确识别目标。

椭圆畸变校正则针对部分倾斜拍摄或广角镜头引起的几何变形问题，通过拟合椭圆边缘并仿射变换实现表盘的几何重建，使仪表区域更加接近真实的圆形结构。处理后图像中的表盘形状更加标准，边界框与实际目标更加对齐，从而提高了后续检测的精度与稳定性。

6.3.3 指针式仪表特征识别结果

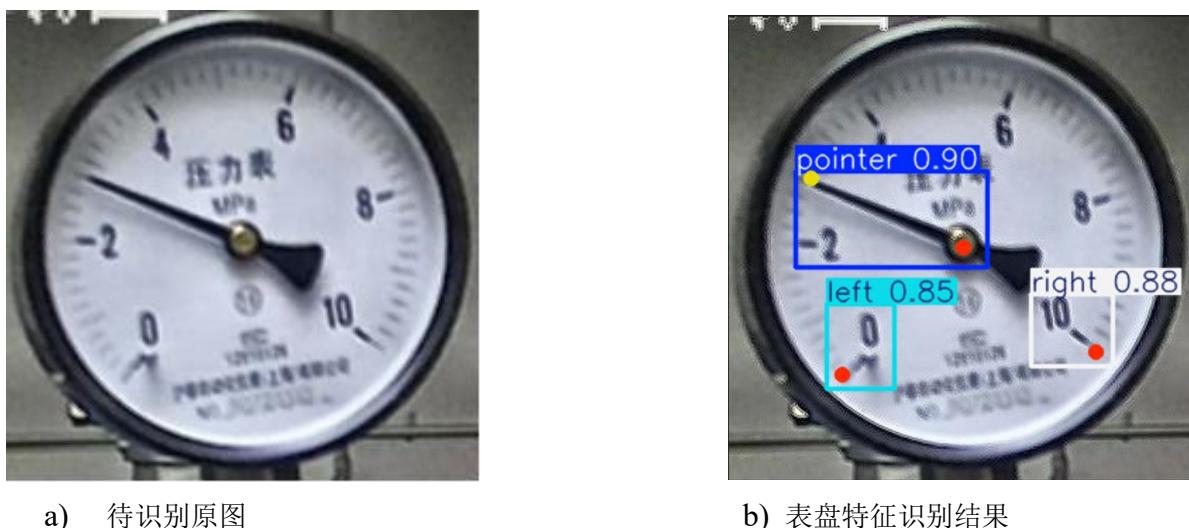


图 6-10 指针式仪表表盘特征识别结果

由上文的指针式仪表特征识别（指针与刻度始末区域）模型训练结果分析可以得知，指针式仪表表盘表盘特征（指针与刻度始末区域）的识别准确率高达 93.8%，但在极少数情况下（如光照条件恶劣指针阴影较强时）可能会存在识别不准确的情况。

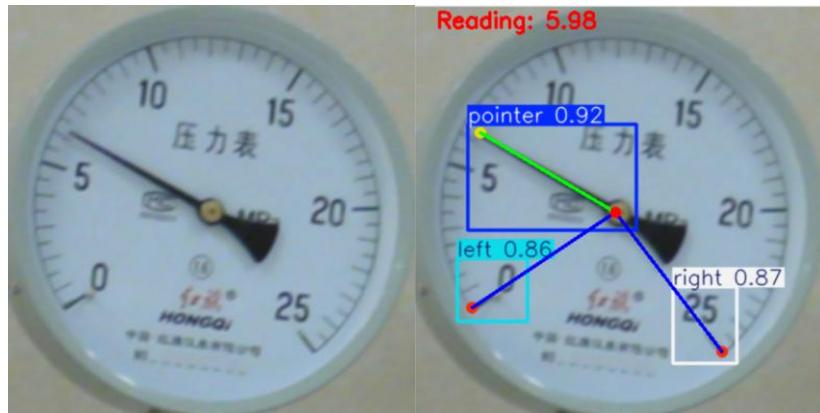
6.3.4 指针式仪表示数读数结果



a) 待读数原图

b) 表盘特征识别结果

图 6-11 指针式仪表读数结果 (1)



a) 待读数原图

b) 表盘特征识别结果

图 6-12 指针式仪表读数结果 (2)

图 6-11 与图 6-12 展示了两个比较典型的读数结果示例。其中，图 6-11 的识别结果与真实值完全一致，显示出极高的准确性；图 6-12 的读数则与真实值存在约 0.04 的微小偏差，整体仍保持较高的识别精度。上述结果表明所提方法在实际应用中具备良好的鲁棒性与可靠性。

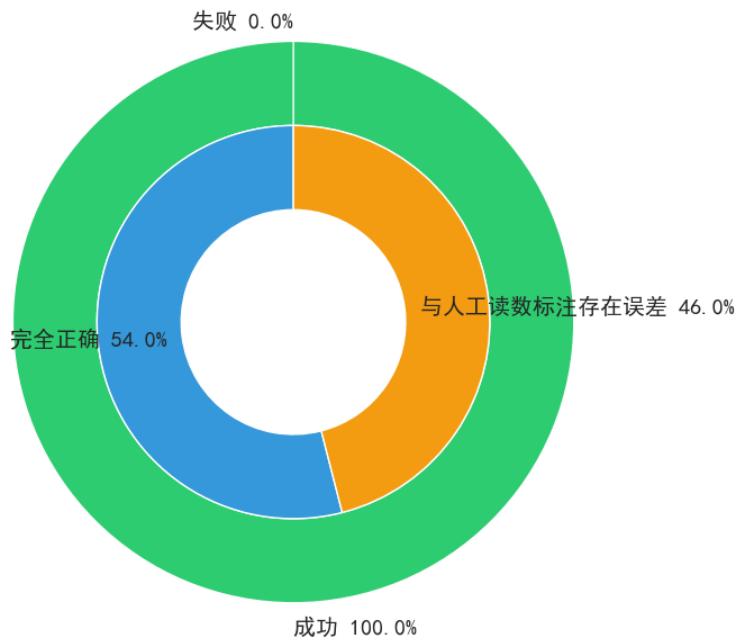


图 6-13 仪表指针读数系统成功率与正确率

从图 6-13 可见，本系统在 50 个测试样本中实现了 100% 的读数成功率，其中 54% 的读数结果与人工完全一致，表明系统具有良好的稳定性与准确性。

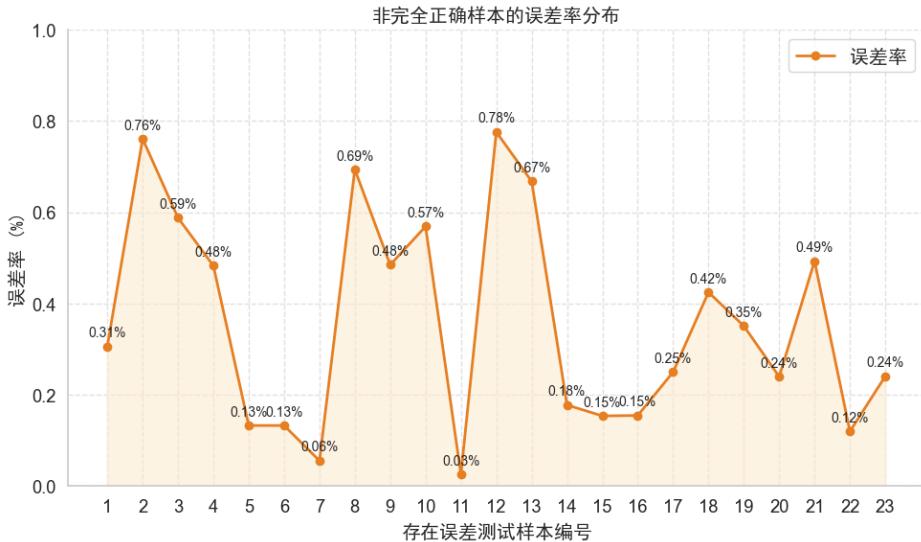


图 6-14 非完全正确样本的误差率分布

图 6-14 进一步展示了其余 23 个存在误差的读数，其误差均控制在 0.8% 以内，可以发现大部分误差小于 0.5%，说明本系统即便在存在微小误差的情况下，整体读数精度依然非常可观，可以基本满足工程使用需求。

6.3.5 指针式仪表读数小结

指针式仪表读数系统在测试数据集的评估中，读数成功率为 100%，且读数结果与人工标注值之间的平均相对误差控制在 0.8% 以内，已经满足多数工业表盘读数精度需求。

6.4 本章小结

本章围绕指针式仪表自动读数系统各模块实验的结果展开了详细介绍，并通过实验验证了所设计的各模块在实际应用中的有效性和可行性。

本模块使用的 2 个训练模型均达到了较高的精度：指针式仪表表盘检测模型在测试数据集的正确率为 97%；指针式仪表特征识别（指针与刻度始末区域）模型在测试数据集的正确率为 93.8%。

指针式仪表读数系统在测试数据集的评估中，读数成功率为 100%，且读数结果与人工标注值之间的平均相对误差控制在 0.8% 以内，满足多数工业表盘读数精度需求。

本功能各模块均通过定量实验证了其性能。模型检测精度高、图像处理效果显著、读数结果准确，充分表明本系统具备良好的实用性和工程应用潜力。

结论

1. 论文工作总结

本文设计并实现了一种基于 YOLOv8 模型的自动仪表读数系统，经验证可以成功应用于数显式和指针式两类仪表的图像处理与识别。系统在本地硬件条件下选择了轻量级的 YOLOv8n 模型，充分考虑了模型的计算量和参数量，优化了系统的运行效率和调试过程，在确保高精度的同时，达到了性能与资源效率的平衡。

在数显式仪表读数系统中，设计了数显区域检测、图像增强及数字识别模块，确保了数字与特殊符号的精准识别，并通过自主研发的数显仪表数字排列读取算法实现了准确的读数解析。而在指针式仪表读数系统中，通过表盘区域检测、图像增强及畸变校正等技术，成功实现了指针与刻度区域的精确定位，并采用自主研发的指针仪表指针夹角读数算法准确地计算了指示读数。

实验结果表明，系统在各个模块上均表现出了较高的准确性：指针式仪表表盘检测模型正确率为 97%，数显式仪表数显区域检测模型正确率为 92.68%，数显式仪表表示数识别模型正确率为 88%，指针式仪表特征识别模型正确率为 93.8%。在测试数据集的评估中，数显式仪表读数系统读数准确率为 96.4%，指针式仪表读数系统读数成功率为 100%，且读数结果与人工标注值之间的平均相对误差控制在 0.8% 以内，充分满足了工业表盘读数精度需求。

因此本文所设计的自动仪表读数系统具有较高的实用性与工程应用潜力，能够为电力、化工、水务等行业的自动巡检与远程监控提供有效的技术支持。

2. 工作展望

虽然该系统已实现相对完整的数字和指针类型展示读取功能，但仍有许多方面可以进一步改进。

尽管当前模型在实验数据集上表现良好，但在面对复杂环境变化和仪器外观差异时，其稳健性和泛化能力仍需提升。未来，增加额外的训练数据（如各种不同环境条件中的表盘以加强模型对于环境的适应性）以及改进数据增强策略可能有助于提高模型在不同环境下的表现。

本文采用了 YOLOv8n 模型，其在低资源硬件上的表现较好。然而，随着应用需求的增加，可能需要进一步优化模型的计算效率与硬件适应性。未来可考虑在嵌入式设备或移动终端上进行部署，结合硬件加速技术（如 GPU、TPU）进一步提升系统的响应速度与实时性能。

本系统目前主要针对单一类型的仪表进行读数处理，未来可以进一步扩展为支持多类型仪表的自动识别与读数，尤其是在复杂工业环境下的复合场景中，结合多模态数据处理方法以应对复杂背景、光照变化等挑战。

自动抄表系统的功能现在可以与监测遥测、智能预测故障诊断和自我诊断等增强功能集成，这得益于工业互联网和集成智能制造的出现。

通过上述优化和拓展，自动抄表系统将有助于在其他工业领域实现进一步应用。这将有助于行业的现代化和自动化进程。

参考文献

- [1] Laroca, R., Barroso, V., Diniz, M. A., Zanlorensi, L. A., Gonçalves, G. R., Todt, E., & Menotti, D. (2019). Convolutional Neural Networks for Automatic Meter Reading. arXiv preprint arXiv:1902.09600. <https://arxiv.org/abs/1902.09600>
- [2] Salomon, G., Laroca, R., & Menotti, D. (2020). Deep Learning for Image-based Automatic Dial Meter Reading: Dataset and Baselines. arXiv preprint arXiv:2005.03106. <https://arxiv.org/abs/2005.03106>
- [3] Imran, M., Hassan, M. U., Abbas, H., Sajjad, M., & Mehmood, I. (2022). Image-Based Automatic Energy Meter Reading Using Deep Learning. Computers, Materials & Continua, 74(1), 1593–1610. <https://www.techscience.com/cmc/v74n1/49788>
- [4] Liu, Y., Zhang, Z., Li, H., Zhu, W., & Liu, X. (2023). Deep Learning-Based Pointer Meter Reading Recognition for Industrial Applications. Sensors, 23(1), 244. <https://www.mdpi.com/1424-8220/23/1/244>
- [5] Khan, F. M., Ali, S., Nawaz, S. R., Ahmed, N., & Islam, M. U. (2022). Deep Learning and Optical Character Recognition for Digitization of Meter Reading. ResearchGate. <https://www.researchgate.net/publication/361281611>
- [6] 周登科, 杨颖, 朱杰, 等. 基于深度学习的指针式仪表倾斜校正方法[J]. 计算机辅助设计与图形学学报, 2020, 32(12): 1976–1984.
- [7] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[EB/OL]. (2022-07-06) [2025-04-30]. Available: <https://arxiv.org/abs/2207.02696>.
- [8] Elfwing S, Uchibe E, Doya K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural Netw, 2018, 107: 3–11.
- [9] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI, USA: IEEE, 2017: 2117–2125.
- [10] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Salt Lake City, UT, USA: IEEE, 2018: 8759–8768.

[11] Tan M, Pang R, Le Q V. EfficientDet: Scalable and efficient object detection[C]//

Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition
(CVPR). Seattle, WA, USA: IEEE, 2020: 10781–10790.

[12] Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding YOLO series in 2021[EB/OL].

(2021-07-16) [2025-04-30]. Available: <https://arxiv.org/abs/2107.08430>.

[13] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
Honolulu, HI, USA: IEEE, 2017: 2117–2125.

[14] Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding YOLO series in 2021[EB/OL].

(2021-07-16) [2025-04-30]. Available: <https://arxiv.org/abs/2107.08430>.

致谢

时光飞逝，转眼间我的四年本科之旅即将画上句号。站在终点回首这段充实而又难忘的旅程，从最初对一切的一知半解，到如今独立完成一篇毕业论文，离不开许多人在我的成长路上的帮助与陪伴。在论文即将完成之际，我想借此机会，向所有给予我支持和鼓励的人表达最真挚的感谢。

首先，最感谢的是我的指导老师吴瀚聪老师。吴老师不仅在课题选题、实验设计、模型训练和论文写作等方面给予我耐心细致的指导，还在每一次交流中都鼓励我深入思考，敢于创新。在我思路受阻、陷入瓶颈时，吴老师总能给予启发与信心，带我逐步梳理思路、理清方向。老师严谨治学、平易近人的风格，让我深受影响，也让我更加坚定了继续学习、深入研究的信心。

我也要衷心感谢在研究过程中给予我巨大帮助的师兄。在我刚接触 CV 和深度学习相关知识时，是师兄耐心为我理清思路，毫无保留地分享经验。师兄的建议总能让我柳暗花明、事半功倍。

除此之外，我最想感谢的还有我的父母。四年来他们始终默默支持着我，无论我选择什么方向，遇到什么困难，父母总是我最坚强的后盾。是他们的鼓励让我在迷茫时不放弃，在焦虑时保持坚定，在失败中重新站起来。他们的理解与包容，是我最珍贵的力量源泉。

最后，也要感谢我的同学们。在论文写作的这段时间，大家互相鼓励、分享资料、交流思路，让原本枯燥的过程变得轻松了许多。我们一起熬夜调模型，一起吐槽代码，一起为实验结果而激动不已——这些都将成为我大学回忆中最温暖的部分。

这篇毕业论文不仅是我本科学习的一个总结，更是我成长过程中的一块重要里程碑。再次感谢所有在这条路上给予我帮助与鼓励的人。